Análisis cuantitativo y cualitativo

Taller segundo momento - Modelos lineales generalizados

Silvia Katerin Angel Camargo

24 de octubre de 2026

Índice

Origen de los datasets **2**

Ejercicio 1. Regresión logística binaria: abandono de clientes **3**

1.1. Carga y revisión de datos 3

1.2. Variables y análisis exploratorio 6

1.3. Formulación y ajuste del modelo 10

1.4. Probabilidades estimadas, matriz de confusión y exactitud (datos de prueba) 13

1.5. Conclusión del ejercicio 1 17

Ejercicio 2. Regresión logística multinomial: tipos de vino **18**

2.1. Carga y revisión de datos 18

2.2. Variables y análisis exploratorio 20

2.3. Formulación y ajuste del modelo 23

2.4. Probabilidades estimadas, matriz de confusión y exactitud (datos de prueba) 26

2.5. Estabilidad del modelo 30

2.6. Conclusión del ejercicio 2 34

Origen de los datasets

Ejercicio 1 (abandono de clientes). Se usó la base *Bank Customer Churn Prediction* (archivo `Churn_Modelling.csv`), obtenida de Kaggle. Contiene 10000 clientes de un banco, de Francia, Alemania y España, con variables financieras y sociodemográficas y una variable que indica si el cliente abandonó la entidad.

Ejercicio 2 (tipos de vino). Se usó la base *Wine* (archivo `wine.data`) del UCI Machine Learning Repository (Aeberhard, Coomans y de Vel, 1991), disponible en https://archive.ics.uci.edu/dataset/109/wine. Reúne los resultados de análisis químicos de 178 vinos cultivados en una misma región de Italia, provenientes de tres cultivares distintos, con 13 variables químicas.

Reproducibilidad. Los archivos se leen con rutas relativas, por lo que deben estar en la misma carpeta que este documento `.Rmd` (si `wine.data` no está, se descarga de UCI). Los paquetes faltantes se instalan automáticamente y las particiones de entrenamiento y prueba usan una semilla fija.

```
# Se instalan solo los paquetes que falten
paquetes <- c("ggplot2", "dplyr", "nnet", "knitr")
faltan <- setdiff(paquetes, rownames(installed.packages()))
if (length(faltan) > 0) install.packages(faltan)

library(ggplot2)  # Gráficos
library(dplyr)    # Manipulación de datos
library(nnet)     # Regresión logística multinomial
library(knitr)    # Presentación de tablas

set.seed(2026)    # Reproducibilidad de las particiones
```

```r
# Funciones auxiliares para redactar los porcentajes y p-valores del texto
efecto <- function(o) {
  ifelse(o >= 1,
         paste0("aumentan en ", sprintf("%.1f", (o - 1) * 100), "%"),
         paste0("disminuyen en ", sprintf("%.1f", (1 - o) * 100), "%"))
}
fp <- function(p) ifelse(p < 0.001, "< 0.001", sprintf("%.3f", p))
```

Ejercicio 1. Regresión logística binaria: abandono de clientes

Situación problema: Una entidad bancaria desea identificar factores asociados al abandono de clientes. Se construye un **MLG logístico binario** para estimar la probabilidad de abandono a partir de características financieras y sociodemográficas.

1.1. Carga y revisión de datos

```r
# Base Bank Customer Churn Prediction (Kaggle)
# El archivo debe estar en la misma carpeta que este documento .Rmd
archivo_churn <- "Churn_Modelling.csv"
if (!file.exists(archivo_churn)) {
  stop("No se encuentra Churn_Modelling.csv en la carpeta del documento.")
}
clientes <- read.csv(archivo_churn, stringsAsFactors = FALSE)

# Nombres en minúscula para evitar errores de escritura
names(clientes) <- tolower(names(clientes))

# Estructura, dimensiones y valores faltantes
str(clientes)
```

```
## 'data.frame':    10000 obs. of  14 variables:
##  $ rownumber      : int  1 2 3 4 5 6 7 8 9 10 ...
##  $ customerid     : int  15634602 15647311 15619304 15701354 15737888 15574012 15592531 156
##  $ surname        : chr  "Hargrave" "Hill" "Onio" "Boni" ...
##  $ creditscore    : int  619 608 502 699 850 645 822 376 501 684 ...
##  $ geography      : chr  "France" "Spain" "France" "France" ...
##  $ gender         : chr  "Female" "Female" "Female" "Female" ...
##  $ age            : int  42 41 42 39 43 44 50 29 44 27 ...
##  $ tenure         : int  2 1 8 1 2 8 7 4 4 2 ...
##  $ balance        : num  0 83808 159661 0 125511 ...
##  $ numofproducts  : int  1 1 3 2 1 2 2 4 2 1 ...
##  $ hascrcard      : int  1 0 1 0 1 1 1 1 0 1 ...
##  $ isactivemember : int  1 1 0 0 1 0 1 0 1 1 ...
##  $ estimatedsalary: num  101349 112543 113932 93827 79084 ...
##  $ exited         : int  1 0 1 0 0 1 0 1 0 0 ...
```

```
dim(clientes)
```

```
## [1] 10000    14
```

```
colSums(is.na(clientes))
```

```
##       rownumber      customerid         surname     creditscore
##               0               0               0               0
##       geography          gender             age          tenure
##               0               0               0               0
##         balance   numofproducts       hascrcard  isactivemember
##               0               0               0               0
## estimatedsalary          exited
##               0               0
```

```r
names(clientes)
```

```
##  [1] "rownumber"       "customerid"      "surname"
##  [4] "creditscore"     "geography"       "gender"
##  [7] "age"             "tenure"          "balance"
## [10] "numofproducts"   "hascrcard"       "isactivemember"
## [13] "estimatedsalary" "exited"
```

```r
# Preparación: tipos de variable y categorías de referencia
# Se renombran las columnas para trabajar con nombres más claros
clientes <- clientes %>%
  rename(any_of(c(
    credit_score = "creditscore", country = "geography",
    products_number = "numofproducts", credit_card = "hascrcard",
    active_member = "isactivemember", estimated_salary = "estimatedsalary",
    churn = "exited"
  )))

# Se retiran los identificadores porque no son predictores
clientes <- clientes %>%
  select(-any_of(c("customer_id", "customerid", "rownumber",
                   "id", "surname"))) %>%
  mutate(
    churn         = as.integer(churn),           # 1 = abandono, 0 = permanece
    country       = relevel(factor(country), ref = "France"),
    gender        = relevel(factor(gender), ref = "Male"),
    balance_miles = balance / 1000               # saldo en miles
  )
```

Descripción del conjunto de datos: La base contiene 10000 registros y 11 variables

originales (después de retirar los identificadores: número de fila, id y apellido del cliente): puntaje de crédito, país, género, edad, antigüedad, saldo, número de productos, tenencia de tarjeta de crédito, cliente activo, salario estimado y la variable de abandono. El total de valores faltantes es 0.

1.2. Variables y análisis exploratorio

Variable respuesta: `churn`, con 1 = el cliente abandonó el banco y 0 = el cliente permanece.

Variables predictoras seleccionadas: `credit_score` (la solvencia puede influir en la permanencia), `country` y `gender` (diferencias sociodemográficas), `age` (el ciclo de vida del cliente), `tenure` (antigüedad como vínculo con el banco), `balance_miles` (nivel de recursos en el banco), `products_number` (profundidad de la relación) y `active_member` (nivel de uso). Se excluyen `credit_card` y `estimated_salary` por aportar poca información adicional en un primer modelo y para mantenerlo parsimonioso.

```
# Tabla de frecuencias de la variable respuesta
tab_churn <- table(Abandono = clientes$churn)
tab_churn
```

```
## Abandono
##    0    1
## 7963 2037
```

```
round(100 * prop.table(tab_churn), 1)
```

```
## Abandono
##    0    1
## 79.6 20.4
```

```r
# Tasas de abandono por grupo (para la interpretación)
tasa      <- mean(clientes$churn)
tasa_pais <- tapply(clientes$churn, clientes$country, mean)
tasa_act  <- tapply(clientes$churn, clientes$active_member, mean)
edad_med  <- tapply(clientes$age, clientes$churn, mean)

# Resumen descriptivo de las variables elegidas
summary(clientes[, c("credit_score", "age", "tenure", "balance_miles",
                     "products_number")])
```

```
##   credit_score        age            tenure       balance_miles
##  Min.   :350.0   Min.   :18.00   Min.   : 0.000   Min.   :  0.00
##  1st Qu.:584.0   1st Qu.:32.00   1st Qu.: 3.000   1st Qu.:  0.00
##  Median :652.0   Median :37.00   Median : 5.000   Median : 97.20
##  Mean   :650.5   Mean   :38.92   Mean   : 5.013   Mean   : 76.49
##  3rd Qu.:718.0   3rd Qu.:44.00   3rd Qu.: 7.000   3rd Qu.:127.64
##  Max.   :850.0   Max.   :92.00   Max.   :10.000   Max.   :250.90
##  products_number
##  Min.   :1.00
##  1st Qu.:1.00
##  Median :1.00
##  Mean   :1.53
##  3rd Qu.:2.00
##  Max.   :4.00
```

```r
ggplot(clientes, aes(x = factor(churn))) +
  geom_bar(fill = "steelblue") +
  labs(x = "Abandono (0 = no, 1 = sí)", y = "Número de clientes") +
  theme_minimal()
```

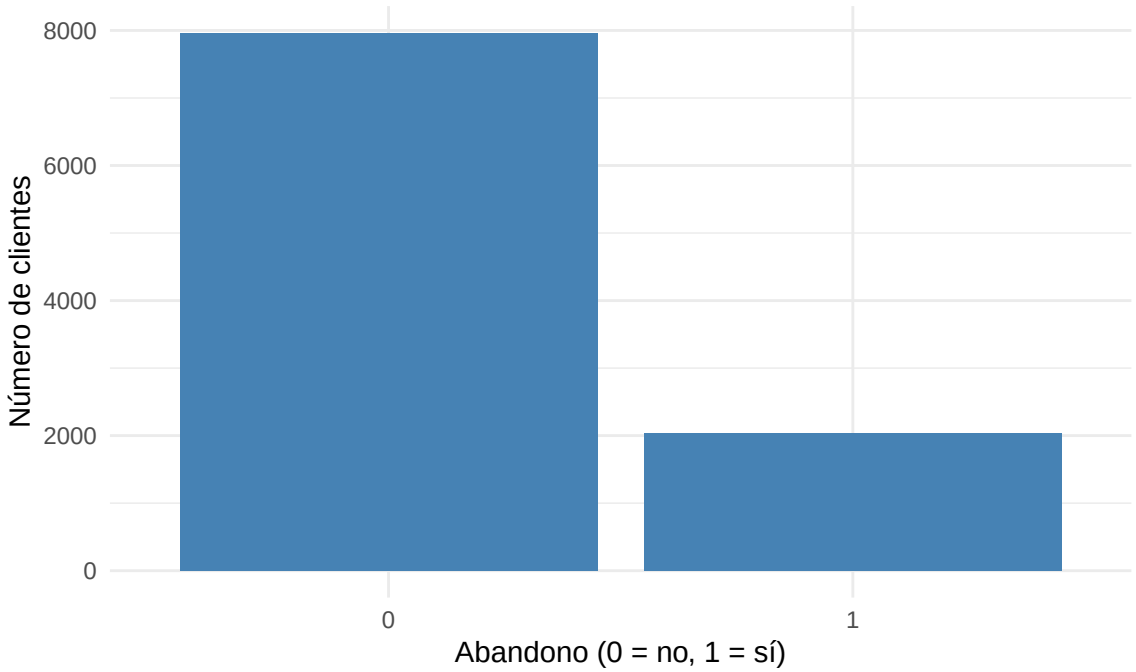


Figura 1: Distribución del abandono de clientes.

```
ggplot(clientes, aes(x = factor(churn), y = age)) +
  geom_boxplot(fill = "lightblue") +
  labs(x = "Abandono (0 = no, 1 = sí)", y = "Edad (años)") +
  theme_minimal()
```

```
clientes %>%
  group_by(country, active_member) %>%
  summarise(tasa = mean(churn), .groups = "drop") %>%
  ggplot(aes(x = country, y = tasa, fill = factor(active_member))) +
  geom_col(position = "dodge") +
  labs(x = "País", y = "Tasa de abandono", fill = "Cliente activo") +
  theme_minimal()
```

Interpretación del análisis exploratorio: La tasa global de abandono es de 20.4 %, por lo que la clase de interés es minoritaria (base desbalanceada). La edad promedio de quienes abandonan es 44.8 años, frente a 37.4 años de quienes permanecen, lo que sugiere que

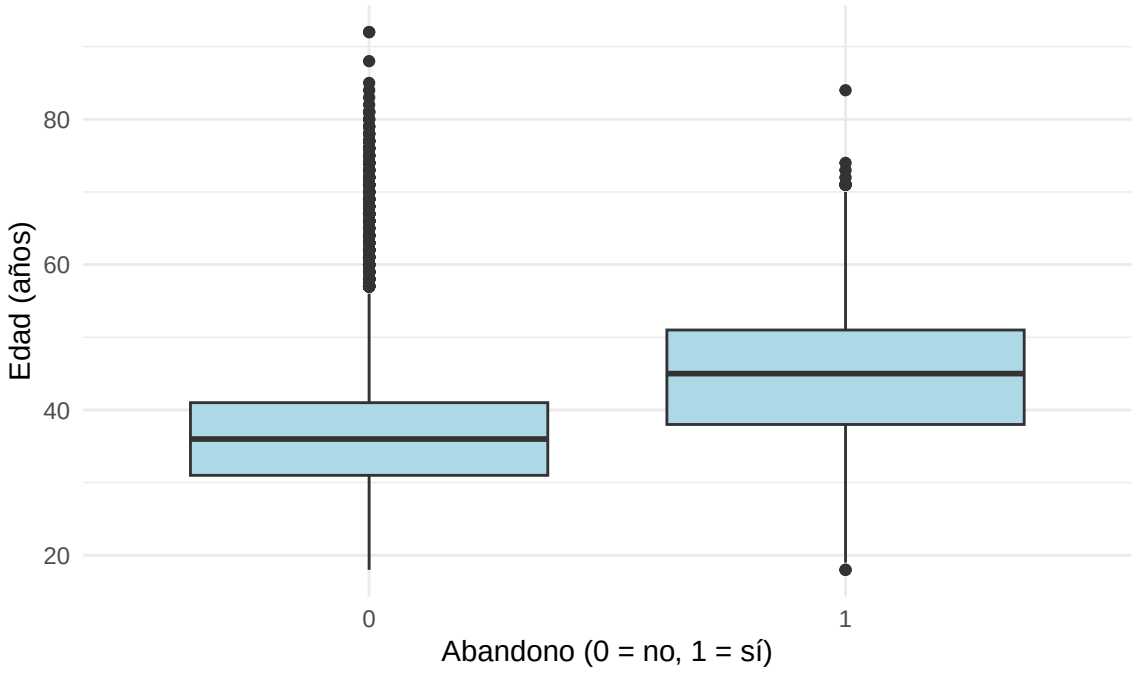


Figura 2: Edad de los clientes según abandono.

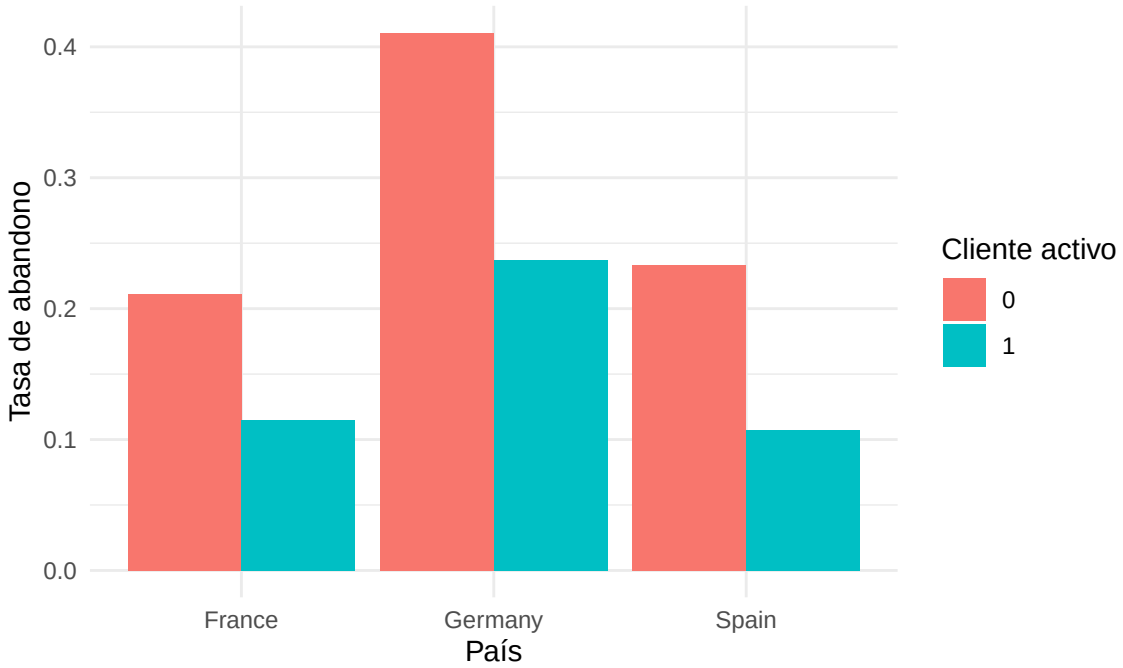


Figura 3: Tasa de abandono por país y condición de cliente activo.

la edad se asocia con el abandono. La tasa de abandono de los clientes no activos es 26.9 %, frente a 14.3 % de los activos. Por país, las tasas son France 16.2 %; Germany 32.4 %; Spain 16.7 %.

1.3. Formulación y ajuste del modelo

Pregunta de análisis: ¿Cómo se relacionan la edad, el saldo, la actividad, el país, el género y la relación con el banco (productos y antigüedad) con la probabilidad de que un cliente abandone?

Modelo y enlace: Familia binomial; enlace logit.

Categoría de referencia / evento de interés: El evento codificado como 1 es el **abandono**. Las categorías de referencia de los factores son `France` (país) y `Male` (género).

```
# Partición entrenamiento (80 %) y prueba (20 %)
n <- nrow(clientes)
idx_train <- sample(seq_len(n), size = floor(0.8 * n))
train <- clientes[idx_train, ]
test  <- clientes[-idx_train, ]

# Ajuste del modelo con los datos de entrenamiento
modelo_binario <- glm(
  churn ~ credit_score + country + gender + age + tenure +
          balance_miles + products_number + active_member,
  data = train,
  family = binomial(link = "logit")
)
summary(modelo_binario)
```

```
##
## Call:
## glm(formula = churn ~ credit_score + country + gender + age +
```

```
##     tenure + balance_miles + products_number + active_member,
##     family = binomial(link = "logit"), data = train)
##
## Coefficients:
##                   Estimate Std. Error z value Pr(>|z|)
## (Intercept)     -3.9397264  0.2660619 -14.808  < 2e-16 ***
## credit_score    -0.0007039  0.0003149  -2.235   0.0254 *
## countryGermany   0.8684606  0.0756451  11.481  < 2e-16 ***
## countrySpain     0.0731584  0.0791636   0.924   0.3554
## genderFemale     0.4798108  0.0609859   7.868 3.62e-15 ***
## age              0.0719485  0.0028649  25.114  < 2e-16 ***
## tenure          -0.0109784  0.0104779  -1.048   0.2947
## balance_miles    0.0026585  0.0005790   4.591 4.41e-06 ***
## products_number -0.0718582  0.0525913  -1.366   0.1718
## active_member   -1.0644723  0.0644785 -16.509  < 2e-16 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## (Dispersion parameter for binomial family taken to be 1)
##
##     Null deviance: 8067.1  on 7999  degrees of freedom
## Residual deviance: 6834.3  on 7990  degrees of freedom
## AIC: 6854.3
##
## Number of Fisher Scoring iterations: 5
```

```r
# Razones de momios (odds ratios) con IC de Wald al 95%
est <- summary(modelo_binario)$coefficients
ic  <- confint.default(modelo_binario)
tab_or <- data.frame(
```

```
  Coeficiente = est[, 1],
  OR          = exp(est[, 1]),
  IC_inf      = exp(ic[, 1]),
  IC_sup      = exp(ic[, 2]),
  p_valor     = est[, 4]
)
kable(round(tab_or, 4),
      caption = "Coeficientes, razones de momios (OR) e IC al 95 %.")
```

Tabla 1: Coeficientes, razones de momios (OR) e IC al 95 %.

	Coeficiente	OR	IC_inf	IC_sup	p_valor
(Intercept)	-3.9397	0.0195	0.0115	0.0328	0.0000
credit_score	-0.0007	0.9993	0.9987	0.9999	0.0254
countryGermany	0.8685	2.3832	2.0548	2.7641	0.0000
countrySpain	0.0732	1.0759	0.9213	1.2565	0.3554
genderFemale	0.4798	1.6158	1.4337	1.8209	0.0000
age	0.0719	1.0746	1.0686	1.0807	0.0000
tenure	-0.0110	0.9891	0.9690	1.0096	0.2947
balance_miles	0.0027	1.0027	1.0015	1.0038	0.0000
products_number	-0.0719	0.9307	0.8395	1.0317	0.1718
active_member	-1.0645	0.3449	0.3040	0.3914	0.0000

```
OR <- exp(coef(modelo_binario))
P  <- est[, 4]
```

Interpretación de los coeficientes: Un odds ratio (OR) compara momios, no probabilidades.

- *Edad:* el coeficiente es 0.072 ($p < 0.001$) y el OR es 1.075. Por cada año adicional de

edad, y manteniendo constantes las demás variables, los momios de abandono aumentan en 7.5 %.

- *Cliente activo:* el OR es 0.345 ($p < 0.001$). Frente a un cliente no activo, los momios de abandono de un cliente activo disminuyen en 65.5 %.
- *País (Germany vs. France):* el OR es 2.383 ($p < 0.001$); los momios de abandono de los clientes de Alemania aumentan en 138.3 % respecto a los de Francia.
- *Género (Female vs. Male):* el OR es 1.616 ($p < 0.001$); los momios de las mujeres aumentan en 61.6 % respecto a los hombres.
- *Saldo (por cada 1000 unidades):* el OR es 1.003 ($p < 0.001$); los momios aumentan en 0.3 % por cada 1000 unidades adicionales de saldo.

Un OR mayor que 1 (coeficiente positivo) indica mayor momio de abandono; un OR menor que 1 (coeficiente negativo), menor momio. Una variable con p mayor a 0.05 no presenta evidencia suficiente de asociación, ajustando por las demás.

1.4. Probabilidades estimadas, matriz de confusión y exactitud (datos de prueba)

```r
# Probabilidades estimadas para los clientes de prueba
prob_test <- predict(modelo_binario, newdata = test, type = "response")
head(round(prob_test, 3))
```

```
##     1     2    18    27    31    32
## 0.116 0.143 0.034 0.141 0.224 0.062
```

```r
# Clasificación con umbral 0.50
pred_test <- ifelse(prob_test >= 0.50, 1, 0)
cm <- table(Real = factor(test$churn, levels = c(0, 1)),
            Predicho = factor(pred_test, levels = c(0, 1)))
kable(cm,
      caption = "Matriz de confusión en prueba (umbral 0.50).")
```

Tabla 2: Matriz de confusión en prueba (umbral 0.50).

	0	1
0	1524	61
1	320	95

```
exactitud     <- sum(diag(cm)) / sum(cm)
sensibilidad  <- cm["1", "1"] / sum(cm["1", ])
especificidad <- cm["0", "0"] / sum(cm["0", ])
# Exactitud de un clasificador que siempre predice "no abandona"
base_mayor    <- max(prop.table(table(test$churn)))

# Segundo umbral: igual a la tasa de abandono (clase minoritaria)
umbral2 <- mean(train$churn)
pred2 <- ifelse(prob_test >= umbral2, 1, 0)
cm2 <- table(Real = factor(test$churn, levels = c(0, 1)),
             Predicho = factor(pred2, levels = c(0, 1)))
kable(cm2,
      caption = "Matriz de confusión en prueba (umbral = tasa de abandono).")
```

Tabla 3: Matriz de confusión en prueba (umbral = tasa de abandono).

	0	1
0	1118	467
1	129	286

```
exactitud2    <- sum(diag(cm2)) / sum(cm2)
sensibilidad2 <- cm2["1", "1"] / sum(cm2["1", ])
especificidad2 <- cm2["0", "0"] / sum(cm2["0", ])
```

```r
pm <- tapply(prob_test, test$churn, mean)

df_prob <- data.frame(
  prob = prob_test,
  real = factor(test$churn, levels = c(0, 1), labels = c("Permanece", "Abandona"))
)

ggplot(df_prob, aes(x = prob, fill = real)) +
  geom_histogram(bins = 30, color = "white", show.legend = FALSE) +
  geom_vline(xintercept = 0.50, linetype = "dashed") +
  geom_vline(xintercept = umbral2, linetype = "dotted") +
  facet_wrap(~ real, scales = "free_y") +
  labs(x = "Probabilidad estimada de abandono", y = "Número de clientes") +
  theme_minimal()
```

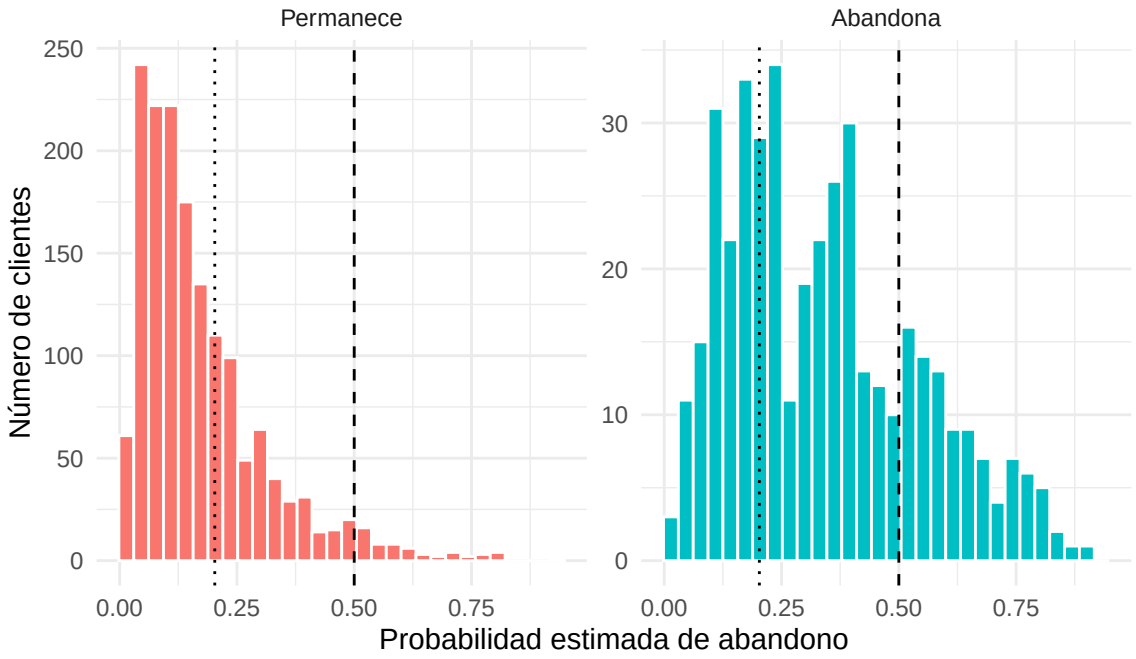


Figura 4: Probabilidades estimadas de abandono en los datos de prueba, según el abandono real (línea discontinua: umbral 0.50; línea punteada: umbral igual a la tasa de abandono).

```r
nuevo <- expand.grid(
  age = 18:90, active_member = c(0, 1),
  credit_score    = mean(train$credit_score),
  tenure          = mean(train$tenure),
  balance_miles   = mean(train$balance_miles),
  products_number = mean(train$products_number),
  country = factor("France", levels = levels(train$country)),
  gender  = factor("Male", levels = levels(train$gender))
)
nuevo$prob   <- predict(modelo_binario, newdata = nuevo, type = "response")
nuevo$Activo <- factor(nuevo$active_member, levels = c(0, 1), labels = c("No", "Sí"))
ggplot(nuevo, aes(x = age, y = prob, color = Activo)) +
  geom_line(linewidth = 1) +
  labs(x = "Edad (años)", y = "Probabilidad estimada de abandono",
       color = "Cliente activo") +
  theme_minimal()
```

```r
p30 <- function(a) nuevo$prob[nuevo$age == 30 & nuevo$active_member == a]
p60 <- function(a) nuevo$prob[nuevo$age == 60 & nuevo$active_member == a]
```

Lectura de los gráficos: En los clientes de prueba que sí abandonaron, la probabilidad estimada promedio fue 0.339, frente a 0.172 en los que permanecieron, es decir, el modelo asigna probabilidades más altas a quienes se van. Sin embargo, las dos distribuciones se solapan: 77.1 % de los abandonos tiene una probabilidad estimada menor a 0.50, lo que explica la baja sensibilidad con ese umbral. En la curva, para un cliente de Francia, hombre y con las demás variables en su promedio, la probabilidad estimada a los 30 años es 0.100 si no es activo y 0.037 si es activo; a los 60 años pasa a 0.490 y 0.249, respectivamente. La probabilidad crece con la edad en ambos grupos y los clientes activos tienen siempre una probabilidad menor.

Interpretación: Cada probabilidad estimada es la probabilidad que el modelo asigna a que ese cliente abandone, dadas sus características. Con el umbral de 0.50, el modelo obtiene

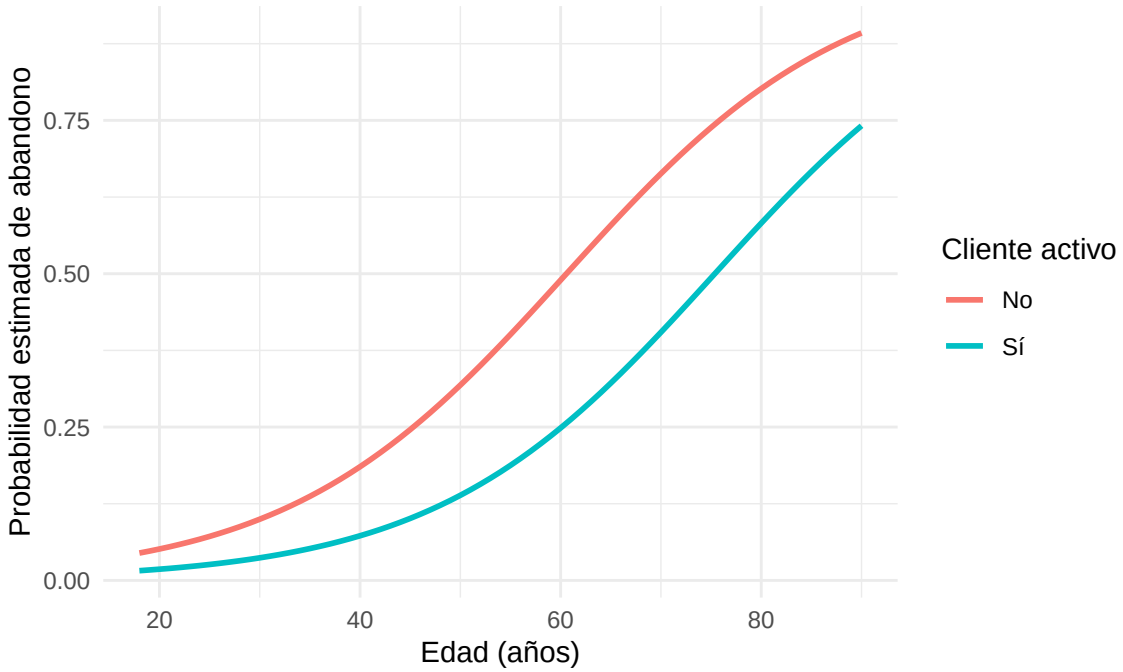


Figura 5: Probabilidad estimada de abandono según la edad y la condición de cliente activo (cliente de Francia, hombre, con las demás variables en su promedio).

en los 2000 clientes de prueba una exactitud de 81.0 %, con sensibilidad (abandonos detectados) de 22.9 % y especificidad de 96.2 %. Como referencia, un clasificador que prediga siempre "no abandona" alcanzaría 79.2 %, de modo que la exactitud por sí sola es engañosa cuando la clase es desbalanceada. Al bajar el umbral a 0.20, la sensibilidad pasa a 68.9 % y la especificidad a 70.5 % (exactitud 70.2 %): se detectan más abandonos a costa de más falsas alarmas. Estos resultados se calcularon con datos que **no** participaron en el ajuste.

1.5. Conclusión del ejercicio 1

El modelo logístico binario permite concluir que el abandono se asocia principalmente con la edad (a mayor edad, los momios de abandono aumentan en 7.5 % por año), con la condición de cliente activo (los activos disminuyen en 65.5 %) y con el país de residencia, además del género (las mujeres presentan momios mayores) y del saldo. En cambio, el puntaje de crédito tiene un efecto pequeño, y la antigüedad, el número de productos y residir en España (frente a Francia) no muestran evidencia de asociación ($p > 0.05$). En datos de prueba la exactitud es de 81.0 %, pero la sensibilidad es de 22.9 %, lo que refleja la principal limitación: al ser el abandono

un evento minoritario, el umbral de 0.50 deja sin detectar a una parte importante de los clientes que se van. Además, el estudio es observacional, por lo que las asociaciones no son causales, y se asumió una relación lineal en el logit para las variables numéricas.

Ejercicio 2. Regresión logística multinomial: tipos de vino

Situación problema: Una empresa desea analizar cómo las características químicas permiten diferenciar tres clases de vino. Se construye un **modelo logístico multinomial** para estimar la probabilidad de pertenencia a cada clase.

2.1. Carga y revisión de datos

```
# Se usa el archivo local "wine.data" si existe; si no, se lee desde UCI.
url_vino <- paste0("https://archive.ics.uci.edu/ml/",
                   "machine-learning-databases/wine/wine.data")
fuente_vino <- if (file.exists("wine.data")) "wine.data" else url_vino
vinos <- read.csv(fuente_vino, header = FALSE)

names(vinos) <- c(
  "class", "Alcohol", "Malicacid", "Ash", "Alcalinity_of_ash",
  "Magnesium", "Total_phenols", "Flavanoids", "Nonflavanoid_phenols",
  "Proanthocyanins", "Color_intensity", "Hue", "OD280_OD315", "Proline"
)

vinos$class <- factor(vinos$class)  # Tres clases nominales
str(vinos)
```

```
## 'data.frame':    178 obs. of  14 variables:
##  $ class               : Factor w/ 3 levels "1","2","3": 1 1 1 1 1 1 1 1 1 1 ...
```

```
##  $ Alcohol             : num  14.2 13.2 13.2 14.4 13.2 ...
##  $ Malicacid           : num  1.71 1.78 2.36 1.95 2.59 1.76 1.87 2.15 1.64 1.35 ...
##  $ Ash                 : num  2.43 2.14 2.67 2.5 2.87 2.45 2.45 2.61 2.17 2.27 ...
##  $ Alcalinity_of_ash   : num  15.6 11.2 18.6 16.8 21 15.2 14.6 17.6 14 16 ...
##  $ Magnesium           : int  127 100 101 113 118 112 96 121 97 98 ...
##  $ Total_phenols       : num  2.8 2.65 2.8 3.85 2.8 3.27 2.5 2.6 2.8 2.98 ...
##  $ Flavanoids          : num  3.06 2.76 3.24 3.49 2.69 3.39 2.52 2.51 2.98 3.15 ...
##  $ Nonflavanoid_phenols: num  0.28 0.26 0.3 0.24 0.39 0.34 0.3 0.31 0.29 0.22 ...
##  $ Proanthocyanins     : num  2.29 1.28 2.81 2.18 1.82 1.97 1.98 1.25 1.98 1.85 ...
##  $ Color_intensity     : num  5.64 4.38 5.68 7.8 4.32 6.75 5.25 5.05 5.2 7.22 ...
##  $ Hue                 : num  1.04 1.05 1.03 0.86 1.04 1.05 1.02 1.06 1.08 1.01 ...
##  $ OD280_OD315         : num  3.92 3.4 3.17 3.45 2.93 2.85 3.58 3.58 2.85 3.55 ...
##  $ Proline             : int  1065 1050 1185 1480 735 1450 1290 1295 1045 1045 ...
```

```
table(vinos$class)
```

```
##
##  1  2  3
## 59 71 48
```

```
colSums(is.na(vinos))
```

```
##                class              Alcohol            Malicacid
##                    0                    0                    0
##                  Ash    Alcalinity_of_ash            Magnesium
##                    0                    0                    0
##       Total_phenols          Flavanoids Nonflavanoid_phenols
##                    0                    0                    0
##     Proanthocyanins      Color_intensity                  Hue
##                    0                    0                    0
##          OD280_OD315              Proline
```

```
##                         0                         0
```

Descripción del conjunto de datos: La base contiene 178 vinos, clasificados en 3 clases (1: 59; 2: 71; 3: 48 vinos) y 13 variables químicas continuas. El total de valores faltantes es 0.

2.2. Variables y análisis exploratorio

Variable respuesta: `class` (clases 1, 2 y 3).

Variables predictoras seleccionadas: `Alcohol`, `Malicacid` y `Color_intensity`. Son variables interpretables para una empresa vinícola y, según el análisis exploratorio, presentan diferencias visibles entre clases.

Categoría de referencia: la clase 1. Cada coeficiente compara la clase 2 (o la 3) **contra la clase 1**, es decir, describe cómo cambian los momios de pertenecer a esa clase en lugar de la clase 1 cuando cambia el predictor.

```
# Tabla de frecuencias por clase
tab_clase <- table(Clase = vinos$class)
tab_clase
```

```
## Clase
##  1  2  3
## 59 71 48
```

```
# Resumen descriptivo de los predictores seleccionados, por clase
res_vinos <- vinos %>%
  group_by(class) %>%
  summarise(across(c(Alcohol, Malicacid, Color_intensity),
                   list(media = mean, de = sd)), .groups = "drop")
kable(res_vinos, digits = 2,
      col.names = c("Clase", "Alcohol media", "Alcohol DE",
```

```
                    "Ác. málico media", "Ác. málico DE",
                    "Color media", "Color DE"),
      caption = "Media y desviación estándar (DE) por clase.")
```

Tabla 4: Media y desviación estándar (DE) por clase.

Clase	Alcohol media	Alcohol DE	Ác. málico media	Ác. málico DE	Color media	Color DE
1	13.74	0.46	2.01	0.69	5.53	1.24
2	12.28	0.54	1.93	1.02	3.09	0.92
3	13.15	0.53	3.33	1.09	7.40	2.31

```
summary(vinos[, c("Alcohol", "Malicacid", "Color_intensity")])
```

```
##     Alcohol        Malicacid     Color_intensity
##  Min.   :11.03   Min.   :0.740   Min.   : 1.280
##  1st Qu.:12.36   1st Qu.:1.603   1st Qu.: 3.220
##  Median :13.05   Median :1.865   Median : 4.690
##  Mean   :13.00   Mean   :2.336   Mean   : 5.058
##  3rd Qu.:13.68   3rd Qu.:3.083   3rd Qu.: 6.200
##  Max.   :14.83   Max.   :5.800   Max.   :13.000
```

```
ggplot(vinos, aes(x = class, y = Alcohol, fill = class)) +
  geom_boxplot(show.legend = FALSE) +
  labs(x = "Clase de vino", y = "Alcohol") +
  theme_minimal()
```

```
ggplot(vinos, aes(x = class, y = Color_intensity, fill = class)) +
  geom_boxplot(show.legend = FALSE) +
  labs(x = "Clase de vino", y = "Intensidad del color") +
  theme_minimal()
```

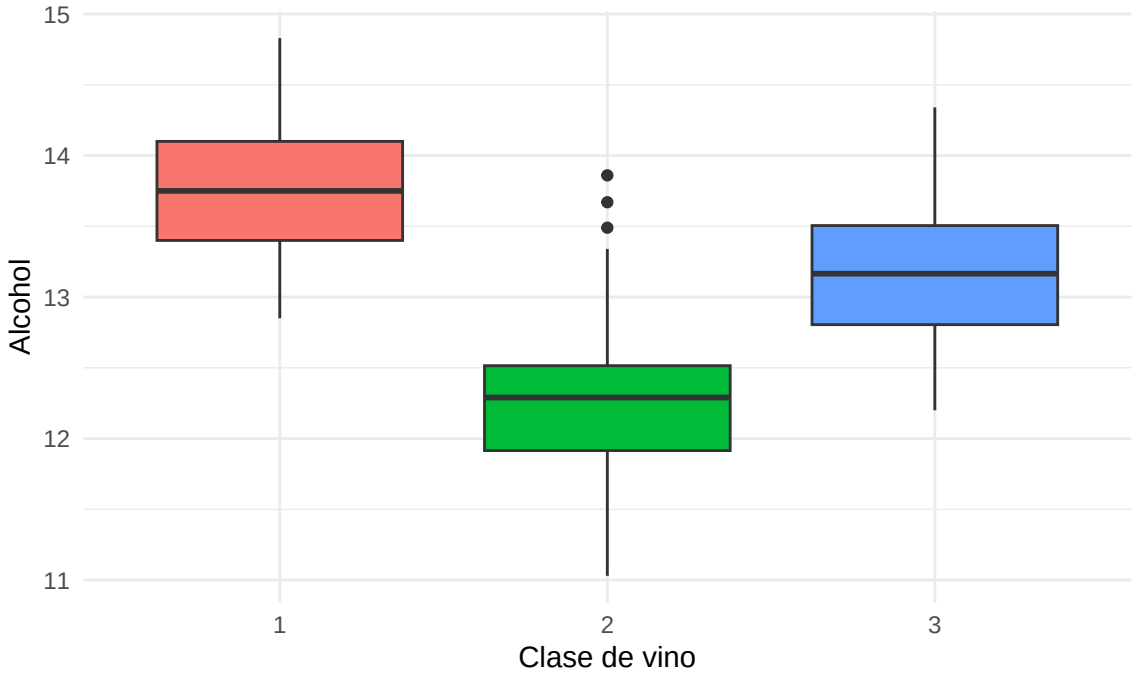


Figura 6: Contenido de alcohol por clase de vino.

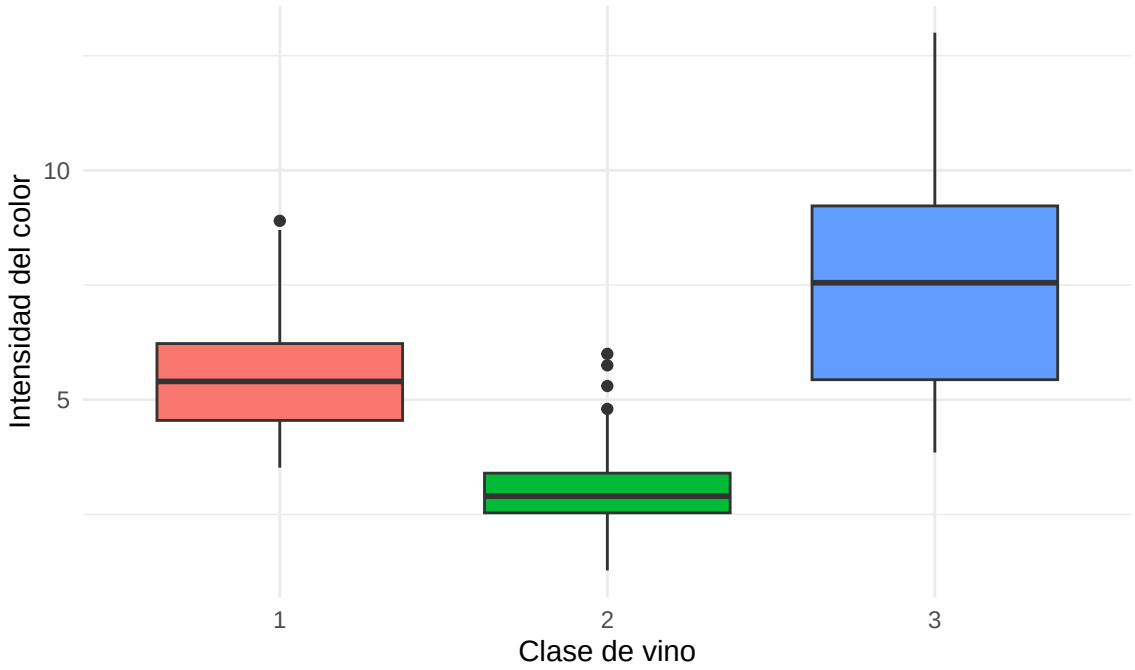


Figura 7: Intensidad del color por clase de vino.

```r
ggplot(vinos, aes(x = class, y = Malicacid, fill = class)) +
  geom_boxplot(show.legend = FALSE) +
  labs(x = "Clase de vino", y = "Ácido málico") +
  theme_minimal()
```

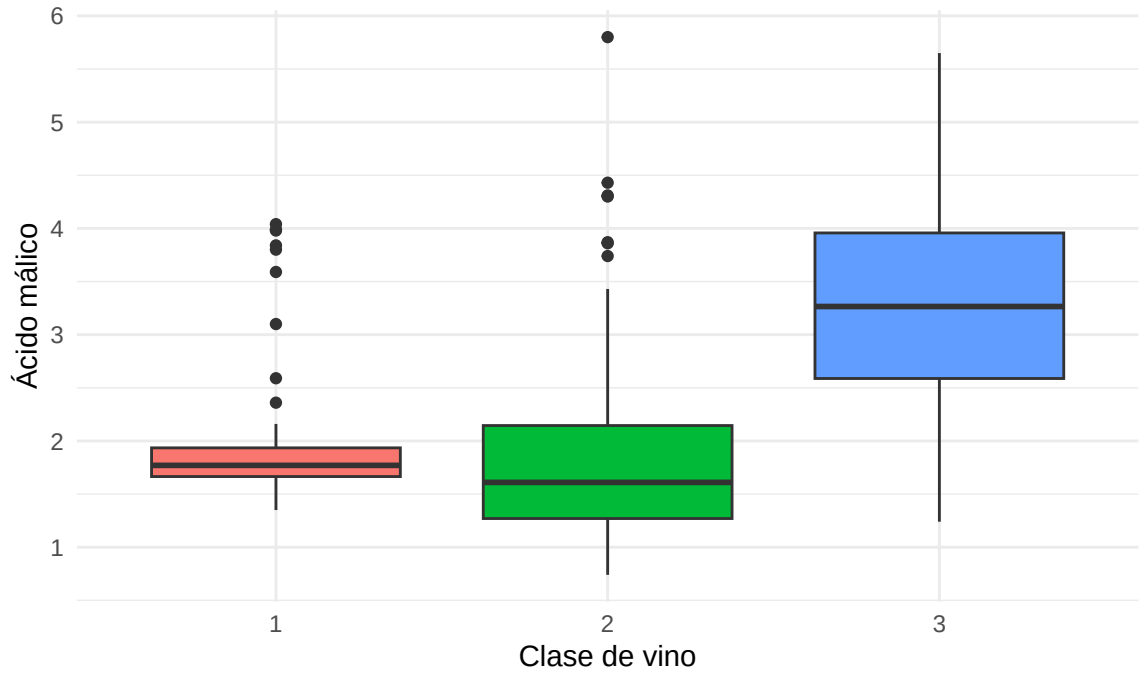


Figura 8: Ácido málico por clase de vino.

Interpretación del análisis exploratorio: Las tres clases están razonablemente balanceadas. La intensidad del color separa bien las clases: la clase 2 tiene los vinos de color menos intenso y la clase 3 los de color más intenso, con la clase 1 en una posicion intermedia. El contenido de alcohol es más alto en la clase 1 y más bajo en la clase 2, con la clase 3 en medio. El ácido málico es claramente mayor en la clase 3, mientras que las clases 1 y 2 son parecidas entre sí. Los valores exactos están en la tabla de medias por clase.

2.3. Formulación y ajuste del modelo

Pregunta de análisis: ¿Cómo se relacionan el contenido de alcohol, el ácido málico y la intensidad del color con la probabilidad de que un vino pertenezca a la clase 2 o a la clase 3, en lugar de a la clase 1?

Modelo: Regresión logística multinomial con categoría de referencia (clase 1).

```r
vinos$class <- relevel(vinos$class, ref = "1")


# Partición estratificada por clase: 70% entrenamiento, 30% prueba
idx_v <- unlist(lapply(split(seq_len(nrow(vinos)), vinos$class),
                       function(i) sample(i, size = round(0.7 * length(i)))))
train_v <- vinos[idx_v, ]
test_v  <- vinos[-idx_v, ]


# Ajuste del modelo multinomial con los datos de entrenamiento
modelo_multi <- multinom(
  class ~ Alcohol + Malicacid + Color_intensity,
  data = train_v,
  trace = FALSE,
  maxit = 500
)
summary(modelo_multi)
```

```
## Call:
## multinom(formula = class ~ Alcohol + Malicacid + Color_intensity,
##     data = train_v, trace = FALSE, maxit = 500)
##
## Coefficients:
##   (Intercept)   Alcohol   Malicacid Color_intensity
## 2    63.13176 -4.339238 -0.02242569       -1.483180
## 3    33.33937 -3.316293  1.73784471        1.019933
##
## Std. Errors:
##   (Intercept)  Alcohol Malicacid Color_intensity
```

```
## 2    15.41535 1.152521  0.421562       0.5657951
## 3    12.32443 0.998012  0.428628       0.2942950
##
## Residual Deviance: 70.9202
## AIC: 86.9202
```

```r
# Coeficientes, errores estándar, z, p-valores y razones (RRR)
co <- coef(modelo_multi)
se <- summary(modelo_multi)$standard.errors
z  <- co / se
pv <- 2 * (1 - pnorm(abs(z)))
RRR <- exp(co)

tab_multi <- do.call(rbind, lapply(rownames(co), function(k) {
  data.frame(Comparacion = paste("Clase", k, "vs 1"),
             Variable = colnames(co),
             Coeficiente = co[k, ], RRR = RRR[k, ], p_valor = pv[k, ],
             row.names = NULL)
}))
# El intercepto no se interpreta, se omite de la tabla
tab_multi <- subset(tab_multi, Variable != "(Intercept)")
kable(tab_multi, digits = 4,
      caption = "Coeficientes y razones de momios (RRR) frente a la clase 1.")
```

Tabla 5: Coeficientes y razones de momios (RRR) frente a la clase 1.

	Comparacion	Variable	Coeficiente	RRR	p_valor
2	Clase 2 vs 1	Alcohol	-4.3392	0.0130	0.0002
3	Clase 2 vs 1	Malicacid	-0.0224	0.9778	0.9576
4	Clase 2 vs 1	Color_intensity	-1.4832	0.2269	0.0088

	Comparacion	Variable	Coeficiente	RRR	p_valor
6	Clase 3 vs 1	Alcohol	-3.3163	0.0363	0.0009
7	Clase 3 vs 1	Malicacid	1.7378	5.6851	0.0001
8	Clase 3 vs 1	Color_intensity	1.0199	2.7730	0.0005

Interpretación de los coeficientes: Todas las comparaciones son respecto a la clase 1. Cada razón (exponencial del coeficiente) se interpreta como el cambio multiplicativo en los momios de pertenecer a la clase indicada, en lugar de la clase 1, por cada aumento de una unidad del predictor y manteniendo los demás constantes.

- *Color_intensity, clase 3 vs 1:* coeficiente 1.020, razón 2.773 (p < 0.001). Por cada unidad adicional de intensidad del color, los momios de ser clase 3 en lugar de clase 1 aumentan en 177.3 %.
- *Color_intensity, clase 2 vs 1:* coeficiente -1.483, razón 0.227 (p 0.009). Los momios de ser clase 2 en lugar de clase 1 disminuyen en 77.3 % por cada unidad adicional de color.
- *Alcohol, clase 2 vs 1:* razón 0.013 (p < 0.001). Por cada punto adicional de alcohol, los momios de ser clase 2 en lugar de clase 1 disminuyen en 98.7 %.
- *Alcohol, clase 3 vs 1:* razón 0.036 (p < 0.001); los momios de ser clase 3 en lugar de clase 1 disminuyen en 96.4 % por cada punto adicional de alcohol.
- *Malicacid, clase 3 vs 1:* razón 5.685 (p < 0.001); los momios de ser clase 3 en lugar de clase 1 aumentan en 468.5 % por cada unidad adicional de ácido málico.

2.4. Probabilidades estimadas, matriz de confusión y exactitud (datos de prueba)

```
# Probabilidades estimadas de las tres clases en los datos de prueba
prob_multi <- predict(modelo_multi, newdata = test_v, type = "probs")
head(round(prob_multi, 3))
```

```
##        1     2     3
```

```
## 5  0.608 0.277 0.115
## 8  0.984 0.004 0.012
## 9  0.999 0.000 0.000
## 14 0.999 0.000 0.001
## 17 0.988 0.000 0.012
## 20 0.772 0.019 0.209
```

```r
# Cada fila suma 1
summary(rowSums(prob_multi))
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##       1       1       1       1       1       1
```

```r
# Probabilidad media asignada a cada clase, según la clase real
prob_media <- aggregate(as.data.frame(prob_multi),
                        by = list(Clase_real = test_v$class), FUN = mean)
kable(prob_media, digits = 3,
      caption = "Probabilidad media estimada por clase real (prueba).")
```

Tabla 6: Probabilidad media estimada por clase real (prueba).

Clase_real	1	2	3
1	0.819	0.112	0.069
2	0.095	0.869	0.036
3	0.162	0.093	0.744

```r
# Clasificación en datos de prueba
pred_multi <- predict(modelo_multi, newdata = test_v, type = "class")
cm_multi <- table(Real = test_v$class, Predicho = pred_multi)
kable(cm_multi, caption = "Matriz de confusión en datos de prueba.")
```

Tabla 7: Matriz de confusión en datos de prueba.

1	2	3
16	2	0
2	18	1
0	2	12

```
exactitud_m <- sum(diag(cm_multi)) / sum(cm_multi)
# Proporción bien clasificada por clase
recall_m <- diag(cm_multi) / rowSums(cm_multi)
recall_m
```

```
##         1         2         3
## 0.8888889 0.8571429 0.8571429
```

```
df_pm <- do.call(rbind, lapply(colnames(prob_multi), function(k) {
  data.frame(real = test_v$class, clase_est = paste("Prob. clase", k),
             prob = prob_multi[, k])
}))
ggplot(df_pm, aes(x = real, y = prob, fill = real)) +
  geom_boxplot(show.legend = FALSE) +
  facet_wrap(~ clase_est) +
  labs(x = "Clase real", y = "Probabilidad estimada") +
  theme_minimal()
```

```
nuevo_v <- data.frame(
  Color_intensity = seq(min(vinos$Color_intensity), max(vinos$Color_intensity),
                        length.out = 100),
  Alcohol   = mean(vinos$Alcohol),
  Malicacid = mean(vinos$Malicacid)
```

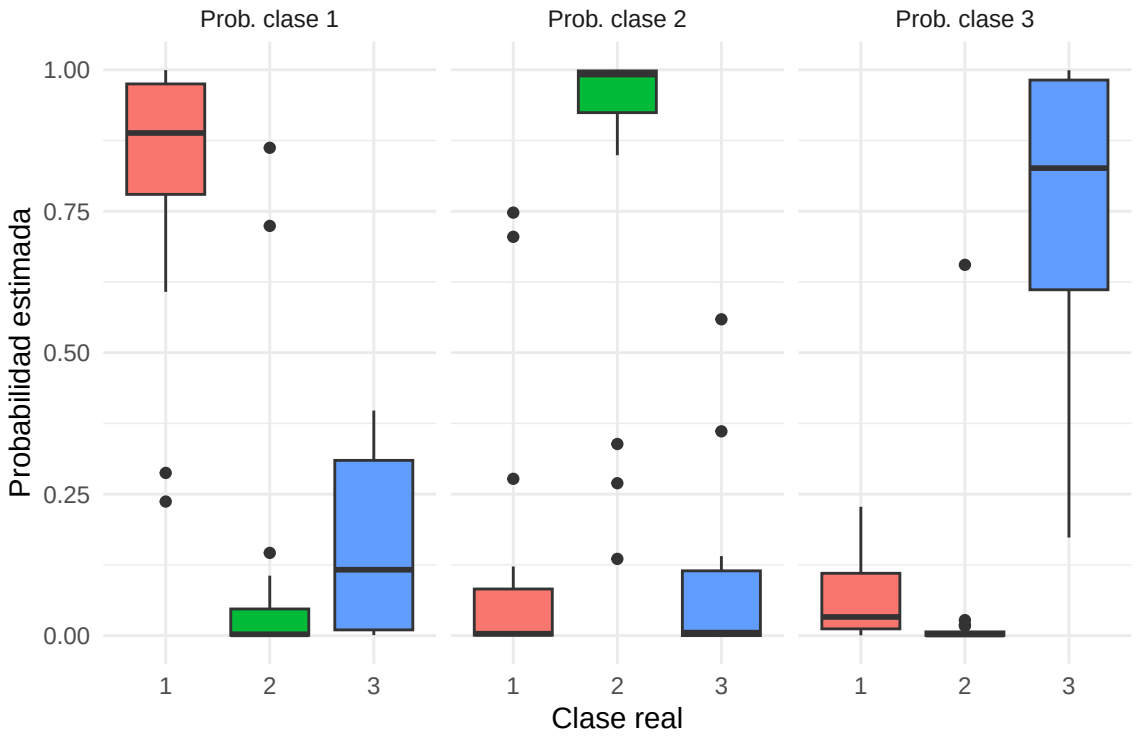


Figura 9: Probabilidades estimadas de cada clase en los datos de prueba, según la clase real.

```
)
pr <- predict(modelo_multi, newdata = nuevo_v, type = "probs")
df_c <- do.call(rbind, lapply(colnames(pr), function(k) {
  data.frame(Color_intensity = nuevo_v$Color_intensity, Clase = k, prob = pr[, k])
}))
ggplot(df_c, aes(x = Color_intensity, y = prob, color = Clase)) +
  geom_line(linewidth = 1) +
  labs(x = "Intensidad del color", y = "Probabilidad estimada") +
  theme_minimal()
```

```
pm_v <- diag(as.matrix(prob_media[, -1]))
```

Lectura de los gráficos: La probabilidad media que el modelo asigna a la clase verdadera es 0.819, 0.869, 0.744 para las clases 1, 2 y 3, respectivamente (las cajas más altas en la diagonal de la primera figura). Respecto a la intensidad del color, con alcohol y ácido málico en

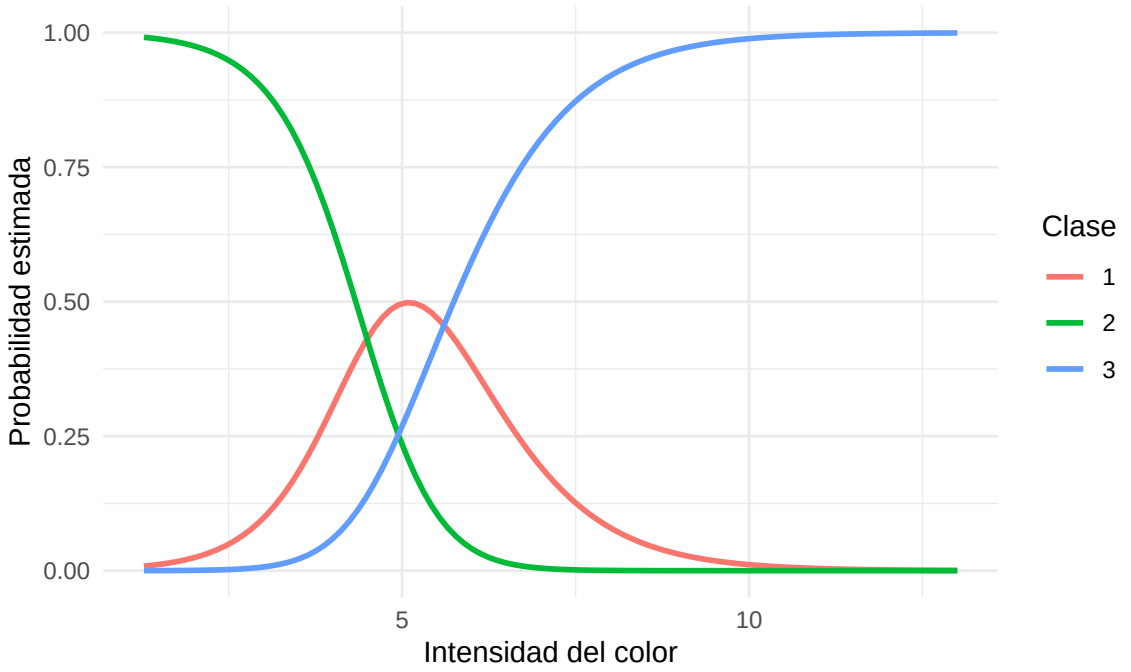


Figura 10: Probabilidad estimada de cada clase según la intensidad del color (alcohol y ácido málico en su promedio).

su promedio, la clase con mayor probabilidad en el color más bajo observado es la 2 y en el color más alto es la 3; en los valores intermedios las probabilidades se reparten entre clases, que es donde se concentran los errores de clasificación.

Interpretación: Para cada vino, el modelo entrega tres probabilidades (una por clase) que suman 1; la clase predicha es la de mayor probabilidad. En los 53 vinos de prueba, el modelo clasifica correctamente 46, para una exactitud de 86.8 %. La proporción bien clasificada por clase es de 88.9 %, 85.7 %, 85.7 % para las clases 1, 2 y 3, respectivamente. Como la tabla de probabilidades medias muestra, el modelo asigna en promedio su mayor probabilidad a la clase verdadera. Los resultados corresponden a datos no usados en el ajuste, pero la prueba es pequeña (53 vinos), por lo que la exactitud es una estimación con bastante variabilidad.

2.5. Estabilidad del modelo

La exactitud anterior depende de una sola partición con 53 vinos de prueba. Para evaluar qué tan estable es el modelo, se repitió 200 veces la partición estratificada 70 % / 30 %,

ajustando el modelo multinomial en cada una y guardando la exactitud en prueba y los coeficientes.

```
set.seed(123)
B <- 200
acc_rep  <- numeric(B)
coef_rep <- NULL
for (b in 1:B) {
  idx_b <- unlist(lapply(split(seq_len(nrow(vinos)), vinos$class),
                         function(i) sample(i, size = round(0.7 * length(i)))))
  m_b <- multinom(class ~ Alcohol + Malicacid + Color_intensity,
                  data = vinos[idx_b, ], trace = FALSE, maxit = 500)
  pred_b <- predict(m_b, newdata = vinos[-idx_b, ], type = "class")
  acc_rep[b] <- mean(pred_b == vinos$class[-idx_b])
  coef_rep <- rbind(coef_rep, as.vector(coef(m_b)))
}
co_b <- coef(m_b)
colnames(coef_rep) <- as.vector(outer(rownames(co_b), colnames(co_b), paste, sep = ": "))

# Resumen de la exactitud
res_acc <- data.frame(
  Media = mean(acc_rep), DE = sd(acc_rep), Minimo = min(acc_rep),
  P2.5 = quantile(acc_rep, 0.025), Mediana = median(acc_rep),
  P97.5 = quantile(acc_rep, 0.975), Maximo = max(acc_rep),
  row.names = NULL
)
kable(round(100 * res_acc, 1),
      caption = "Exactitud en prueba (%) en 200 particiones aleatorias.")
```

Tabla 8: Exactitud en prueba (%) en 200 particiones aleatorias.

Media	DE	Minimo	P2.5	Mediana	P97.5	Maximo
86.5	3.6	75.5	79.2	86.8	92.5	98.1

```r
ggplot(data.frame(acc = 100 * acc_rep), aes(x = acc)) +
  geom_histogram(bins = 15, fill = "steelblue", color = "white") +
  geom_vline(xintercept = 100 * mean(acc_rep), linetype = "dashed") +
  labs(x = "Exactitud en prueba ( %)", y = "Número de particiones") +
  theme_minimal()
```

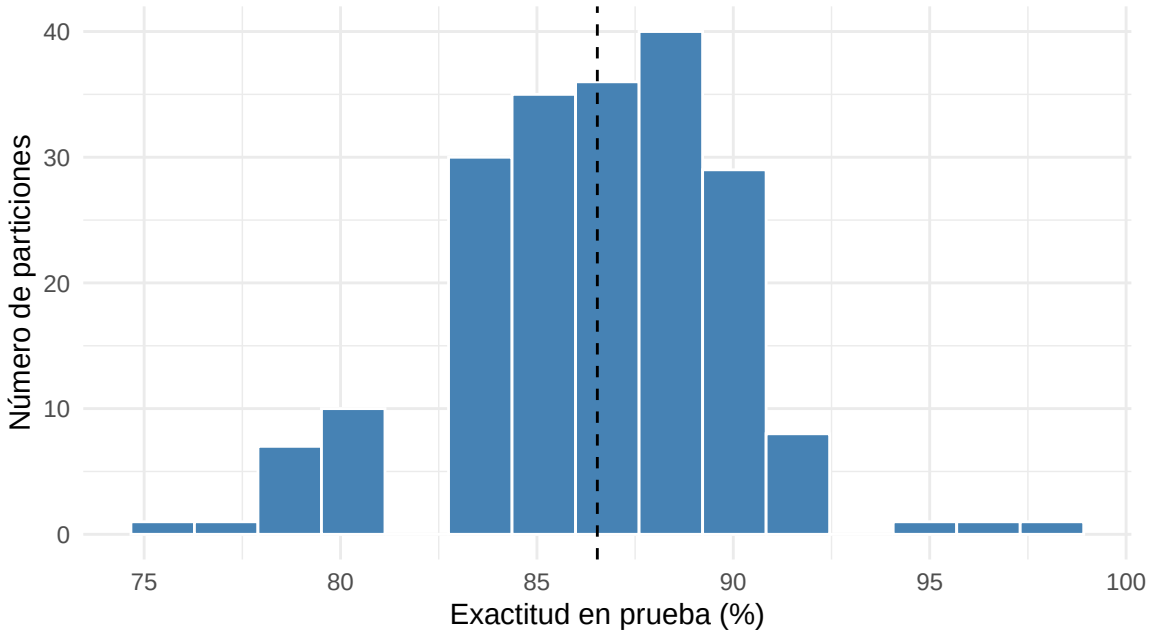


Figura 11: Distribución de la exactitud en datos de prueba al repetir la partición 200 veces (línea: media).

```r
# Estabilidad de los coeficientes (sin interceptos)
cr <- coef_rep[, !grepl("Intercept", colnames(coef_rep))]
tab_est <- data.frame(
  Coeficiente = colnames(cr),
  Media       = colMeans(cr),
  DE          = apply(cr, 2, sd),
```

```
  RRR_mediana = exp(apply(cr, 2, median)),
  RRR_p2.5    = exp(apply(cr, 2, quantile, 0.025)),
  RRR_p97.5   = exp(apply(cr, 2, quantile, 0.975)),
  Mismo_signo = 100 * apply(cr, 2, function(x) mean(sign(x) == sign(mean(x)))),
  row.names = NULL
)
kable(tab_est, digits = 3,
      col.names = c("Coeficiente", "Media", "DE", "RRR mediana", "RRR P2.5",
                    "RRR P97.5", "% mismo signo"),
      caption = "Estabilidad de los coeficientes en 200 particiones.")
```

Tabla 9: Estabilidad de los coeficientes en 200 particiones.

Coeficiente	Media	DE	RRR mediana	RRR P2.5	RRR P97.5	% mismo signo
2: Alcohol	-4.940	0.925	0.009	0.001	0.028	100.0
3: Alcohol	-3.773	0.611	0.026	0.005	0.062	100.0
2: Malicacid	-0.198	0.461	0.860	0.227	1.782	66.5
3: Malicacid	1.795	0.283	5.878	3.892	11.556	100.0
2: Color_intensity	-1.688	0.651	0.208	0.052	0.397	100.0
3: Color_intensity	1.176	0.202	3.163	2.398	5.164	100.0

```
incluyen1 <- tab_est$Coeficiente[tab_est$RRR_p2.5 < 1 & tab_est$RRR_p97.5 > 1]
texto_inc <- if (length(incluyen1) > 0) paste(incluyen1, collapse = ", ") else "ninguno"
menos_est <- tab_est$Coeficiente[which.min(tab_est$Mismo_signo)]
# Criterios para el veredicto: DE de la exactitud <= 3 puntos y
# signo igual en al menos 95% de las repeticiones
acc_estable   <- sd(acc_rep) <= 0.03
signo_estable <- min(tab_est$Mismo_signo) >= 95
```

Interpretación: Al repetir la partición, la exactitud en prueba tuvo una media de 86.5 %

y una desviación estándar de 3.6 puntos; el 95 % central de los valores está entre 79.2 % y 92.5 %, con extremos de 75.5 % y 98.1 %. La exactitud de 86.8 % obtenida con la partición inicial es, por lo tanto, una de las muchas posibles, y lo razonable es reportar el rango. En cuanto a los coeficientes, el signo se mantuvo en al menos el 66.5 % de las repeticiones en todos los casos; el coeficiente menos estable fue 2: Malicacid. Los intervalos de las razones de riesgo relativo que incluyen el valor 1 (sin efecto) corresponden a: 2: Malicacid. **En resumen:** la exactitud varía bastante entre particiones (desviación estándar de 3.6 puntos; se considera estable si es de 3 puntos o menos) y la dirección de algunos efectos no es estable (2: Malicacid cambia de signo en parte de las repeticiones) (el signo se mantiene en al menos 95 % de las repeticiones en cada coeficiente). Por lo tanto, el modelo no puede considerarse completamente estable y sus resultados deben interpretarse con cautela, dado el tamaño reducido de la muestra (178 vinos).

2.6. Conclusión del ejercicio 2

Con tres variables químicas (alcohol, ácido málico e intensidad del color) el modelo multinomial distingue los tres tipos de vino con una exactitud de 86.8 % en datos de prueba. La intensidad del color y el contenido de alcohol son las características que más ayudan a diferenciar las clases frente a la clase 1 (ver los p-valores de la tabla de coeficientes), y el ácido málico aporta sobre todo para identificar la clase 3. Como limitaciones, la muestra es pequeña (178 vinos) y los predictores se usaron en su escala original. Al repetir 200 veces la partición, la exactitud promedio fue de 86.5 % (desviación estándar de 3.6 puntos), por lo que conviene reportar la exactitud como un rango y no como un valor único.

Comparación final de los modelos

Aspecto	Logístico binario	Logístico multinomial
Número de categorías de respuesta	2 (abandona / no abandona)	3 (clases de vino 1, 2 y 3)
Categoría de referencia	No abandona (0); se modela la probabilidad del evento 1	Clase 1; las clases 2 y 3 se comparan contra ella
Interpretación de coeficientes	Un solo conjunto de coeficientes; exp(coef) es el OR del abandono frente a la permanencia	Un conjunto de coeficientes por cada clase frente a la referencia; exp(coef) es la razón de momios de esa clase frente a la clase 1
Tipo de probabilidades estimadas	Una probabilidad, P(abandono), con P(no abandono) = 1 - P	Un vector de tres probabilidades que suma 1; se clasifica en la de mayor valor

Reflexión final: El modelo binario se usa cuando la respuesta tiene dos categorías, como abandona o no abandona; el multinomial, cuando hay tres o más categorías nominales sin orden, como los tipos de vino. En ambos casos, interpretar las probabilidades y los odds ratios describe la **asociación** entre predictores y respuesta en los datos con que se ajustó el modelo, mientras que comprobar el desempeño con datos nuevos mide si el modelo **generaliza**. Un modelo puede ajustar bien la muestra de entrenamiento y fallar con observaciones nuevas, por eso se reservaron datos de prueba para la matriz de confusión y la exactitud. Además, en el caso binario la exactitud sola puede ser engañosa si una clase es minoritaria.