# Abandono de clientes bancarios mediante regresión logística binaria

Silvia Katerin Angel Camargo

24 de octubre de 2026

## Índice

**1. Propósito del informe** **2**

**2. Librerías y ubicación de los archivos** **2**

**3. Importación y preparación de los datos** **3**

**4. Análisis exploratorio** **7**

4.1. Distribución general del abandono . . . . . 9

4.2. Diferencias por país . . . . . 10

4.3. Diferencias según actividad . . . . . 11

4.4. Distribución de edad según abandono . . . . . 11

**5. Partición estratificada: entrenamiento y prueba** **12**

**6. Modelo lineal generalizado logístico** **13**

**7. Significancia y odds ratios** **15**

**8. Evaluación del ajuste en entrenamiento** **17**

**9. Probabilidades estimadas según perfiles** **18**

**10. Evaluación con datos de prueba** **20**

10.1. Matriz de confusión en prueba . . . . . 22

10.2. Curva ROC en prueba . . . . . 23

10.3. Indicadores de clasificación en prueba . . . . . 24

**11. Conclusiones y proyección** **24**

# 1. Propósito del informe

Este documento muestra cómo integrar **explicaciones, código de R, tablas, gráficos e interpretaciones** en un solo informe reproducible usando R Markdown y RStudio. El análisis usa un conjunto de datos didáctico de abandono bancario (*Churn Modelling*). No representa una validación en una entidad bancaria real.

**Pregunta:** ¿Cómo se relacionan la edad, el saldo, el estado de actividad y el país con la probabilidad de que un cliente abandone el banco?

**Variable respuesta:** `Abandono` (0 = permanece; 1 = abandona).

# 2. Librerías y ubicación de los archivos

Antes de compilar el informe, guarde `Churn_Modelling.csv` en la **misma carpeta** que este `.Rmd`. La ruta relativa facilita compartir el proyecto con otros estudiantes sin modificar el nombre de usuario del computador. El directorio de trabajo se establece automáticamente en la carpeta del `.Rmd` al tejer el documento desde RStudio.

```
# 0. LIBRERIAS (instalar solo una vez si es necesario)
# install.packages(c("tidyverse", "rsample", "broom", "knitr", "pROC", "scales", "rmarkdown",
library(tidyverse)
library(rsample)
library(broom)
```

```r
library(knitr)
library(pROC)
library(scales)
```

## 3. Importación y preparación de los datos

Eliminamos columnas identificadoras, revisamos valores faltantes y duplicados por identificador, cambiamos nombres al español y definimos las variables categóricas.

```r
# 2. IMPORTACION Y PREPARACION DE DATOS


Datos <- read.csv("C:\\Users\\Lisbeth Jhoanna\\Documents\\Semana_Inno_Tec\\Resultado_poster\\Cl
# View(Datos)  # Solo para exploración interactiva, no para PDF
dim(Datos)
```

```
[1] 10000    14
```

```r
names(Datos)
```

```
 [1] "RowNumber"       "CustomerId"      "Surname"         "CreditScore"
 [5] "Geography"       "Gender"          "Age"             "Tenure"
 [9] "Balance"         "NumOfProducts"   "HasCrCard"       "IsActiveMember"
[13] "EstimatedSalary" "Exited"
```

```r
str(Datos)
```

```
'data.frame':   10000 obs. of  14 variables:
 $ RowNumber      : int  1 2 3 4 5 6 7 8 9 10 ...
 $ CustomerId     : int  15634602 15647311 15619304 15701354 15737888 15574012 15592531 156561
 $ Surname        : chr  "Hargrave" "Hill" "Onio" "Boni" ...
 $ CreditScore    : int  619 608 502 699 850 645 822 376 501 684 ...
 $ Geography      : chr  "France" "Spain" "France" "France" ...
 $ Gender         : chr  "Female" "Female" "Female" "Female" ...
```

```
$ Age             : int  42 41 42 39 43 44 50 29 44 27 ...
$ Tenure          : int  2 1 8 1 2 8 7 4 4 2 ...
$ Balance         : num  0 83808 159661 0 125511 ...
$ NumOfProducts   : int  1 1 3 2 1 2 2 4 2 1 ...
$ HasCrCard       : int  1 0 1 0 1 1 1 1 0 1 ...
$ IsActiveMember : int  1 1 0 0 1 0 1 0 1 1 ...
$ EstimatedSalary: num  101349 112543 113932 93827 79084 ...
$ Exited          : int  1 0 1 0 0 1 0 1 0 0 ...
```

```r
summary(Datos)
```

```
  RowNumber       CustomerId         Surname            CreditScore
Min.   :    1   Min.   :15565701   Length:10000       Min.   :350.0
1st Qu.: 2501   1st Qu.:15628528   Class :character   1st Qu.:584.0
Median : 5000   Median :15690738   Mode  :character   Median :652.0
Mean   : 5000   Mean   :15690941                      Mean   :650.5
3rd Qu.: 7500   3rd Qu.:15753234                      3rd Qu.:718.0
Max.   :10000   Max.   :15815690                      Max.   :850.0
 Geography            Gender                Age            Tenure
Length:10000       Length:10000       Min.   :18.00   Min.   : 0.000
Class :character   Class :character   1st Qu.:32.00   1st Qu.: 3.000
Mode  :character   Mode  :character   Median :37.00   Median : 5.000
                                      Mean   :38.92   Mean   : 5.013
                                      3rd Qu.:44.00   3rd Qu.: 7.000
                                      Max.   :92.00   Max.   :10.000
   Balance       NumOfProducts    HasCrCard      IsActiveMember
Min.   :     0   Min.   :1.00   Min.   :0.0000   Min.   :0.0000
1st Qu.:     0   1st Qu.:1.00   1st Qu.:0.0000   1st Qu.:0.0000
Median : 97199   Median :1.00   Median :1.0000   Median :1.0000
Mean   : 76486   Mean   :1.53   Mean   :0.7055   Mean   :0.5151
3rd Qu.:127644   3rd Qu.:2.00   3rd Qu.:1.0000   3rd Qu.:1.0000
```

```
 Max.   :250898   Max.   :4.00   Max.   :1.0000   Max.   :1.0000
 EstimatedSalary         Exited
 Min.   :    11.58   Min.   :0.0000
 1st Qu.: 51002.11   1st Qu.:0.0000
 Median :100193.91   Median :0.0000
 Mean   :100090.24   Mean   :0.2037
 3rd Qu.:149388.25   3rd Qu.:0.0000
 Max.   :199992.48   Max.   :1.0000
```

```
# Revisar faltantes y clientes duplicados ANTES de retirar identificadores
colSums(is.na(Datos))
```

```
     RowNumber      CustomerId         Surname     CreditScore       Geography
             0               0               0               0               0
        Gender             Age          Tenure         Balance   NumOfProducts
             0               0               0               0               0
     HasCrCard  IsActiveMember EstimatedSalary          Exited
             0               0               0               0
```

```
sum(duplicated(Datos$CustomerId))
```

```
[1] 0
```

```
# Solo quitamos filas repetidas del mismo identificador; si las hay,
# conviene verificar que no representen movimientos distintos del cliente.
Datos <- Datos %>% distinct(CustomerId, .keep_all = TRUE)


# Retirar identificadores y renombrar columnas
Datos <- Datos %>%
  select(-RowNumber, -CustomerId, -Surname) %>%
  rename(
    Puntaje_Credito = CreditScore,
    Pais = Geography,
```

```
    Genero = Gender,
    Edad = Age,
    Antiguedad = Tenure,
    Saldo = Balance,
    Num_Productos = NumOfProducts,
    Tarjeta_Credito = HasCrCard,
    Cliente_Activo = IsActiveMember,
    Salario_Estimado = EstimatedSalary,
    Abandono = Exited
  ) %>%
  mutate(
    Pais = factor(Pais, levels = c("France", "Germany", "Spain")),
    Genero = factor(Genero),
    Cliente_Activo = factor(Cliente_Activo,
                            levels = c(0, 1), labels = c("No", "Si")),
    Abandono = as.integer(Abandono),
    Saldo_10mil = Saldo / 10000
  )

# Datos completos para las variables del modelo
Datos_modelo <- Datos %>%
  select(Abandono, Edad, Saldo, Saldo_10mil, Cliente_Activo, Pais) %>%
  drop_na()
stopifnot(all(Datos_modelo$Abandono %in% c(0L, 1L)))
```

```
estructura_tabla <- data.frame(
  Variable = names(Datos_modelo),
  Tipo_Dato = sapply(Datos_modelo, function(x) class(x)[1]),
  Valores_Ejemplo = sapply(Datos_modelo, function(x)
    paste(head(na.omit(as.character(x)), 3), collapse = ", "))
```

```
)
knitr::kable(estructura_tabla, caption = "Variables utilizadas en el modelo")
```

**Tabla 1:** Variables utilizadas en el modelo

| | Variable | Tipo_Dato | Valores_Ejemplo |
|---|---|---|---|
| Abandono | Abandono | integer | 1, 0, 1 |
| Edad | Edad | integer | 42, 41, 42 |
| Saldo | Saldo | numeric | 0, 83807.86, 159660.8 |
| Saldo_10mil | Saldo_10mil | numeric | 0, 8.380786, 15.96608 |
| Cliente_Activo | Cliente_Activo | factor | Si, Si, No |
| Pais | Pais | factor | France, Spain, France |

El conjunto limpio contiene **10.000 registros** y **6 variables** para la fase de modelado.

## 4. Análisis exploratorio

```
# 3. ANALISIS EXPLORATORIO
# 3.1 Distribucion de la respuesta
tabla_abandono <- Datos_modelo %>%
  count(Abandono) %>%
  mutate(Grupo = if_else(Abandono == 1, "Abandono", "Permanece"),
         Porcentaje = round(100 * n / sum(n), 1))
knitr::kable(tabla_abandono, caption = "Distribución general del abandono")
```

**Tabla 2:** Distribución general del abandono

| Abandono | n | Grupo | Porcentaje |
|---|---|---|---|
| 0 | 7963 | Permanece | 79.6 |
| 1 | 2037 | Abandono | 20.4 |

```r
# 3.2 Resumen descriptivo por grupo
tabla_resumen <- Datos_modelo %>%
  group_by(Abandono) %>%
  summarise(Clientes = n(),
            Edad_media = round(mean(Edad), 1),
            Edad_mediana = median(Edad),
            Saldo_medio = round(mean(Saldo), 0),
            .groups = "drop")
knitr::kable(tabla_resumen, caption = "Edad y saldo según abandono")
```

**Tabla 3:** Edad y saldo según abandono

| Abandono | Clientes | Edad_media | Edad_mediana | Saldo_medio |
|---|---|---|---|---|
| 0 | 7963 | 37.4 | 36 | 72745 |
| 1 | 2037 | 44.8 | 45 | 91109 |

```r
# 3.3 Proporcion de abandono segun pais
tabla_pais <- Datos_modelo %>%
  group_by(Pais) %>%
  summarise(Clientes = n(), Abandonos = sum(Abandono),
            Porcentaje = round(100 * mean(Abandono), 1), .groups = "drop")
knitr::kable(tabla_pais, caption = "Abandono por país")
```

**Tabla 4:** Abandono por país

| Pais | Clientes | Abandonos | Porcentaje |
|---|---|---|---|
| France | 5014 | 810 | 16.2 |
| Germany | 2509 | 814 | 32.4 |
| Spain | 2477 | 413 | 16.7 |

```r
# 3.4 Proporcion de abandono segun actividad
tabla_activo <- Datos_modelo %>%
  group_by(Cliente_Activo) %>%
  summarise(Clientes = n(), Abandonos = sum(Abandono),
            Porcentaje = round(100 * mean(Abandono), 1), .groups = "drop")
knitr::kable(tabla_activo, caption = "Abandono por actividad")
```

**Tabla 5:** Abandono por actividad

| Cliente_Activo | Clientes | Abandonos | Porcentaje |
|---|---|---|---|
| No | 4849 | 1302 | 26.9 |
| Si | 5151 | 735 | 14.3 |

**Interpretación:** 20.4 % de los clientes abandonó el banco. Las tablas y gráficas permiten examinar diferencias descriptivas, sin atribuirles por sí solas causalidad.

## 4.1. Distribución general del abandono

```r
# Grafica 1: porcentaje general de abandono
g1 <- ggplot(tabla_abandono, aes(x = Grupo, y = Porcentaje, fill = Grupo)) +
  geom_col(width = .55) +
  geom_text(aes(label = paste0(Porcentaje, "%")), vjust = -.4, size = 5) +
  scale_fill_manual(values = c("Abandono" = "#F47721", "Permanece" = "#70218A")) +
  scale_y_continuous(limits = c(0, 100)) +
  labs(title = "¿Que porcentaje de clientes abandona el banco?",
       x = NULL, y = "Porcentaje de clientes") +
  theme_minimal(base_size = 13) + theme(legend.position = "none")
print(g1)
```

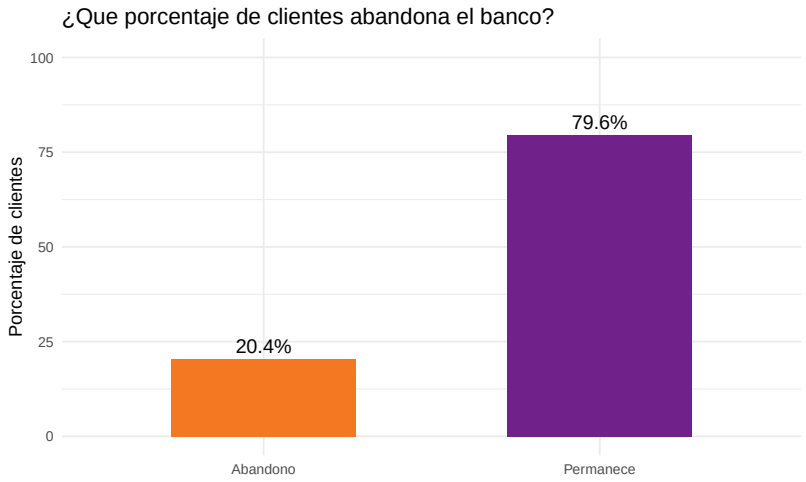



**Figura 1:** Distribución general del abandono

## 4.2. Diferencias por país

```
# Grafica 2: abandono por pais
g2 <- ggplot(tabla_pais, aes(x = Pais, y = Porcentaje)) +
  geom_col(fill = "#70218A", width = .55) +
  geom_text(aes(label = paste0(Porcentaje, "%")), vjust = -.4, size = 5) +
  scale_y_continuous(limits = c(0, max(tabla_pais$Porcentaje) + 8)) +
  labs(title = "Abandono de clientes segun pais", x = "Pais", y = "Porcentaje de abandono") +
  theme_minimal(base_size = 13)
print(g2)
```

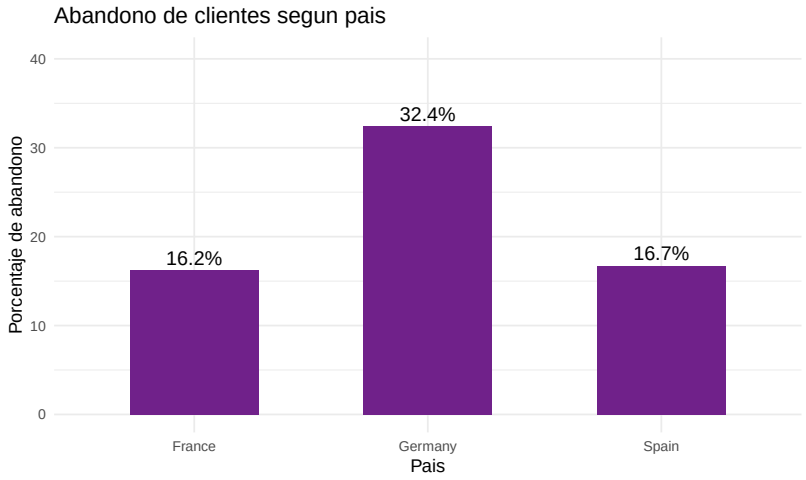



**Figura 2:** Diferencias por país

## 4.3. Diferencias según actividad

```
# Grafica 3: abandono por actividad
g3 <- ggplot(tabla_activo, aes(x = Cliente_Activo, y = Porcentaje)) +
  geom_col(fill = "#F47721", width = .55) +
  geom_text(aes(label = paste0(Porcentaje, "%")), vjust = -.4, size = 5) +
  scale_y_continuous(limits = c(0, max(tabla_activo$Porcentaje) + 8)) +
  labs(title = "Abandono segun actividad del cliente", x = "¿Cliente activo?",
       y = "Porcentaje de abandono") +
  theme_minimal(base_size = 13)
print(g3)
```

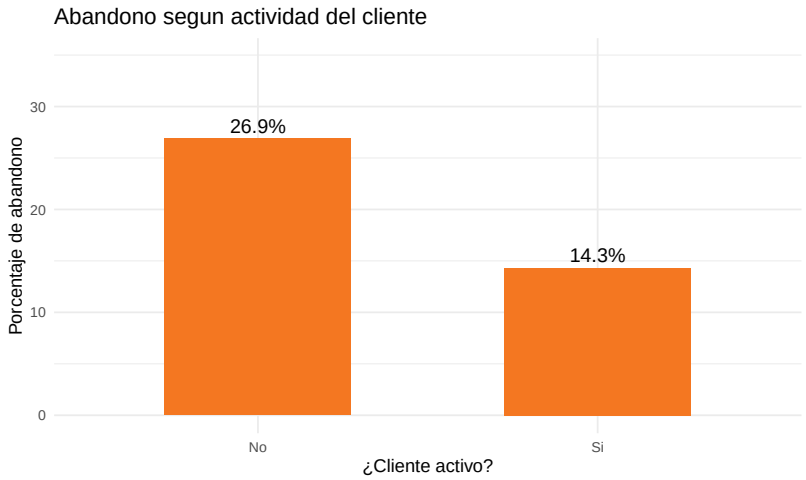



**Figura 3:** Diferencias según actividad

## 4.4. Distribución de edad según abandono

```
# Grafica 4: edad por abandono
g4 <- ggplot(Datos_modelo,
             aes(x = factor(Abandono, levels = c(0, 1),
                            labels = c("Permanece", "Abandona")),
                 y = Edad)) +
  geom_boxplot(fill = "#7B65AB", alpha = .8) +
```

```
  labs(title = "Edad de los clientes segun abandono", x = NULL, y = "Edad (años)") +
  theme_minimal(base_size = 13)
print(g4)
```

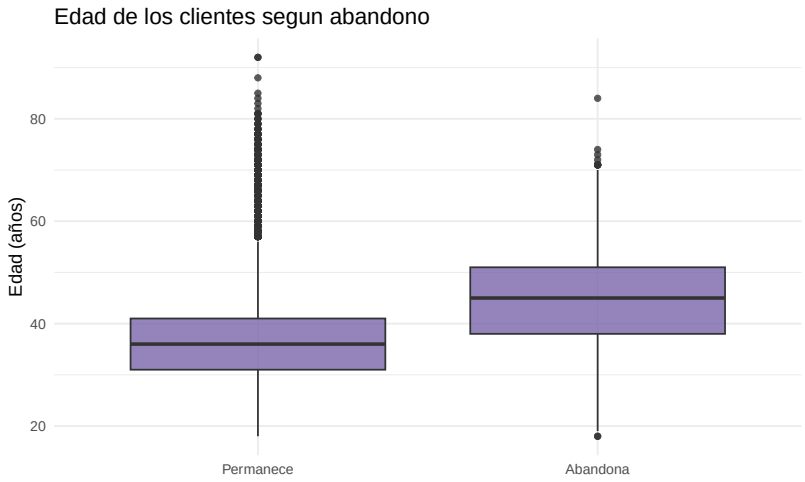



**Figura 4:** Distribución de edad según abandono

## 5. Partición estratificada: entrenamiento y prueba

Reservamos aproximadamente el 20 % de los registros para **prueba**. La estratificación busca mantener una proporción semejante de abandonos en ambos subconjuntos. La muestra de prueba no se usa para ajustar el modelo.

```
# 4. PARTICION ESTRATIFICADA: ENTRENAMIENTO Y PRUEBA
set.seed(2026)
particion <- initial_split(Datos_modelo, prop = 0.80, strata = Abandono)
entrenamiento <- training(particion)
prueba <- testing(particion)
cat("Entrenamiento:", nrow(entrenamiento), "filas\n")
```

```
Entrenamiento: 7999 filas
```

```
cat("Prueba:", nrow(prueba), "filas\n")
```

```
Prueba: 2001 filas
```

```r
# Confirmar que la proporcion de abandono es similar
entrenamiento %>% count(Abandono) %>% mutate(Porcentaje = 100*n/sum(n)) %>% print()
```

```
  Abandono    n Porcentaje
1        0 6370   79.63495
2        1 1629   20.36505
```

```r
prueba %>% count(Abandono) %>% mutate(Porcentaje = 100*n/sum(n)) %>% print()
```

```
  Abandono    n Porcentaje
1        0 1593   79.61019
2        1  408   20.38981
```

El entrenamiento contiene **7999** registros y la prueba **2001**.

## 6. Modelo lineal generalizado logístico

Como la respuesta tiene dos categorías, utilizamos una **familia binomial** con enlace **logit**:

$$\log\left(\frac{p}{1-p}\right) = \beta_0 + \beta_1\, Edad + \beta_2\, Saldo_{10mil} + \beta_3\, Actividad + \beta_4\, Pais.$$

Las variables categóricas generan los coeficientes necesarios para las comparaciones con sus referencias (cliente inactivo y Francia).

```r
# 6. AJUSTE DEL MODELO (SOLO EN ENTRENAMIENTO)
modelo_logistico <- glm(
  Abandono ~ Edad + Saldo_10mil + Cliente_Activo + Pais,
  data = entrenamiento,
  family = binomial(link = "logit")
)
```

```r
summary(modelo_logistico)
```

```
Call:
glm(formula = Abandono ~ Edad + Saldo_10mil + Cliente_Activo +
    Pais, family = binomial(link = "logit"), data = entrenamiento)

Coefficients:
                  Estimate Std. Error z value             Pr(>|z|)
(Intercept)      -4.341726   0.133413  -32.54 < 0.0000000000000002 ***
Edad              0.073036   0.002877   25.39 < 0.0000000000000002 ***
Saldo_10mil       0.030722   0.005496    5.59          0.0000000227 ***
Cliente_ActivoSi -1.122630   0.064446  -17.42 < 0.0000000000000002 ***
PaisGermany       0.758405   0.074667   10.16 < 0.0000000000000002 ***
PaisSpain         0.054714   0.078210    0.70                 0.484
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 8085.7  on 7998  degrees of freedom
Residual deviance: 6917.9  on 7993  degrees of freedom
AIC: 6929.9

Number of Fisher Scoring iterations: 5
```

```r
tabla_modelo <- tidy(modelo_logistico, conf.int = TRUE) %>%
  mutate(OR = exp(estimate), OR_inf = exp(conf.low), OR_sup = exp(conf.high))
knitr::kable(tabla_modelo, digits = 3, caption = "Coeficientes del modelo")
```

**Tabla 6:** Coeficientes del modelo

| term | estimate | std.error | statistic | p.value | conf.low | conf.high | OR | OR_inf | OR_sup |
|---|---|---|---|---|---|---|---|---|---|
| (Intercept) | -4.342 | 0.133 | -32.543 | 0.000 | -4.605 | -4.082 | 0.013 | 0.010 | 0.017 |
| Edad | 0.073 | 0.003 | 25.390 | 0.000 | 0.067 | 0.079 | 1.076 | 1.070 | 1.082 |
| Saldo_10mil | 0.031 | 0.005 | 5.590 | 0.000 | 0.020 | 0.042 | 1.031 | 1.020 | 1.042 |
| Cliente_ActivoSi | -1.123 | 0.064 | -17.420 | 0.000 | -1.250 | -0.997 | 0.325 | 0.287 | 0.369 |
| PaisGermany | 0.758 | 0.075 | 10.157 | 0.000 | 0.612 | 0.905 | 2.135 | 1.845 | 2.472 |
| PaisSpain | 0.055 | 0.078 | 0.700 | 0.484 | -0.099 | 0.207 | 1.056 | 0.905 | 1.230 |

## 7. Significancia y odds ratios

```
# 7. SIGNIFICANCIA ESTADISTICA (ENTRENAMIENTO)
significativas <- tabla_modelo %>%
  filter(term != "(Intercept)", p.value < 0.05) %>% pull(term)
no_significativas <- tabla_modelo %>%
  filter(term != "(Intercept)", p.value >= 0.05) %>% pull(term)
print(significativas)
```

```
[1] "Edad"             "Saldo_10mil"      "Cliente_ActivoSi" "PaisGermany"
```

```
print(no_significativas)
```

```
[1] "PaisSpain"
```

```
# 8. ODDS RATIOS (ENTRENAMIENTO)
tabla_or <- tabla_modelo %>%
  filter(term != "(Intercept)") %>%
  transmute(Variable = term,
            Coeficiente = round(estimate, 3),
            OR = round(OR, 3),
```

```
            IC_95_inferior = round(OR_inf, 3),
            IC_95_superior = round(OR_sup, 3),
            Valor_p = signif(p.value, 3))
knitr::kable(tabla_or, caption = "Odds ratios ajustados e intervalos de confianza")
```

**Tabla 7:** Odds ratios ajustados e intervalos de confianza

| Variable | Coeficiente | OR | IC_95_inferior | IC_95_superior | Valor_p |
|---|---|---|---|---|---|
| Edad | 0.073 | 1.076 | 1.070 | 1.082 | 0.000 |
| Saldo_10mil | 0.031 | 1.031 | 1.020 | 1.042 | 0.000 |
| Cliente_ActivoSi | -1.123 | 0.325 | 0.287 | 0.369 | 0.000 |
| PaisGermany | 0.758 | 2.135 | 1.845 | 2.472 | 0.000 |
| PaisSpain | 0.055 | 1.056 | 0.905 | 1.230 | 0.484 |

Un **odds ratio mayor que 1** representa mayores odds de abandono, y uno **menor que 1**, menores odds, bajo el modelo ajustado y manteniendo constantes las demás variables. Los coeficientes son **asociaciones**, no efectos causales.

```
# Grafica 5: odds ratios ajustados con IC 95%
g5 <- tabla_modelo %>%
  filter(term != "(Intercept)") %>%
  mutate(Variable = recode(term,
                           "Edad" = "Edad (por año)",
                           "Saldo_10mil" = "Saldo (por 10.000)",
                           "Cliente_ActivoSi" = "Cliente activo: Si vs No",
                           "PaisGermany" = "Alemania vs Francia",
                           "PaisSpain" = "España vs Francia")) %>%
  ggplot(aes(x = reorder(Variable, OR), y = OR)) +
  geom_hline(yintercept = 1, linetype = "dashed", color = "grey40") +
  geom_pointrange(aes(ymin = OR_inf, ymax = OR_sup), color = "#70218A", linewidth = .6) +
  coord_flip() +
```

```
  scale_y_log10() +
  labs(title = "Factores asociados al abandono bancario",
       subtitle = "Odds ratios ajustados e IC del 95 % | Entrenamiento",
       x = NULL, y = "Odds ratio (escala logaritmica)") +
  theme_minimal(base_size = 12)
print(g5)
```

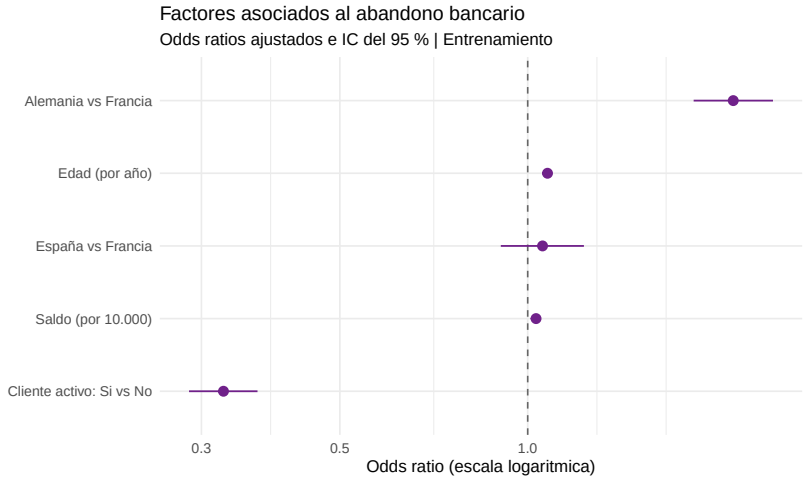



**Figura 5:** Odds ratios ajustados con intervalos de confianza del 95 %

## 8. Evaluación del ajuste en entrenamiento

```
# 9. EVALUACION DEL AJUSTE (EN ENTRENAMIENTO)
dev_nula <- modelo_logistico$null.deviance
dev_resid <- modelo_logistico$deviance
aic_val <- AIC(modelo_logistico)
modelo_nulo <- update(modelo_logistico, . ~ 1)
pseudo_r2 <- 1 - as.numeric(logLik(modelo_logistico)) /
  as.numeric(logLik(modelo_nulo))

tabla_ajuste <- data.frame(
  Metrica = c("Devianza nula", "Devianza residual", "AIC", "Pseudo R2 de McFadden"),
```

```
  Valor = round(c(dev_nula, dev_resid, aic_val, pseudo_r2), 3)
)
knitr::kable(tabla_ajuste, caption = "Medidas de ajuste en entrenamiento")
```

**Tabla 8:** Medidas de ajuste en entrenamiento

| Metrica | Valor |
|---|---|
| Devianza nula | 8085.734 |
| Devianza residual | 6917.941 |
| AIC | 6929.941 |
| Pseudo R2 de McFadden | 0.144 |

La devianza y el AIC informan sobre el ajuste y permiten comparar modelos apropiados sobre los mismos datos. El pseudo-$R^2$ de McFadden **no** se interpreta como porcentaje de varianza explicada.

## 9. Probabilidades estimadas según perfiles

```
# 10. VISUALIZACION DE PROBABILIDADES ESTIMADAS
# Perfiles hipoteticos a saldo mediano, inactivos en Francia.
nuevos_datos_edad <- expand.grid(
  Edad = seq(min(entrenamiento$Edad), max(entrenamiento$Edad), length.out = 100),
  Saldo_10mil = median(entrenamiento$Saldo_10mil),
  Cliente_Activo = levels(entrenamiento$Cliente_Activo),
  Pais = levels(entrenamiento$Pais)
)
pred_edad <- predict(modelo_logistico, newdata = nuevos_datos_edad,
                     type = "link", se.fit = TRUE)
nuevos_datos_edad <- nuevos_datos_edad %>%
  mutate(Probabilidad = plogis(pred_edad$fit),
```

```
        Limite_Inferior = plogis(pred_edad$fit - 1.96 * pred_edad$se.fit),
        Limite_Superior = plogis(pred_edad$fit + 1.96 * pred_edad$se.fit))


g6 <- ggplot(nuevos_datos_edad,
             aes(x = Edad, y = Probabilidad, color = Cliente_Activo,
                 fill = Cliente_Activo)) +
  geom_ribbon(aes(ymin = Limite_Inferior, ymax = Limite_Superior),
              alpha = .15, color = NA) +
  geom_line(linewidth = 1.1) +
  facet_wrap(~ Pais) +
  scale_y_continuous(labels = percent_format(accuracy = 1), limits = c(0, 1)) +
  labs(title = "Probabilidad estimada de abandono segun edad",
       subtitle = "Comparacion por actividad y pais; saldo constante en la mediana",
       x = "Edad (años)", y = "Probabilidad de abandono",
       color = "Cliente activo", fill = "Cliente activo") +
  theme_minimal(base_size = 12) + theme(legend.position = "bottom")
print(g6)
```

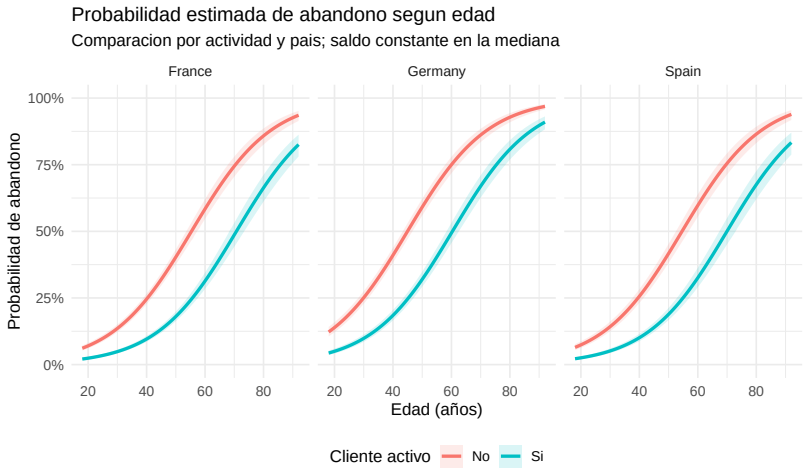



**Figura 6:** Probabilidad estimada de abandono según edad, actividad y país

Se comparan perfiles hipotéticos manteniendo constante el saldo. Las bandas representan intervalos de confianza aproximados del 95 % para la probabilidad estimada por el modelo.

## 10. Evaluación con datos de prueba

Aplicamos el modelo entrenado a observaciones no utilizadas para calcular los coeficientes. Con un umbral de **0,50**, las probabilidades se convierten en clases predichas.

```
# 11. EVALUACION CON DATOS DE PRUEBA (NUEVO)
# No se utiliza 'prueba' para ajustar coeficientes ni elegir variables.
prueba <- prueba %>%
  mutate(Probabilidad = predict(modelo_logistico, newdata = prueba,
                                type = "response"),
         Prediccion = if_else(Probabilidad >= 0.50, 1L, 0L))

# Matriz: filas = real, columnas = predicho
matriz <- table(
  Real = factor(prueba$Abandono, levels = c(0, 1)),
  Predicho = factor(prueba$Prediccion, levels = c(0, 1))
)
knitr::kable(matriz, caption = "Matriz de confusión (prueba)")
```

**Tabla 9:** Matriz de confusión (prueba)

| | 0 | 1 |
|---|---|---|
| 0 | 1549 | 44 |
| 1 | 326 | 82 |

```
VN <- unname(matriz["0", "0"])
FP <- unname(matriz["0", "1"])
FN <- unname(matriz["1", "0"])
VP <- unname(matriz["1", "1"])
exactitud <- (VP + VN) / sum(matriz)
sensibilidad <- if ((VP + FN) > 0) VP / (VP + FN) else NA_real_
```

```r
especificidad <- if ((VN + FP) > 0) VN / (VN + FP) else NA_real_
precision <- if ((VP + FP) > 0) VP / (VP + FP) else NA_real_
f1 <- if (is.finite(precision) && is.finite(sensibilidad) &&
          (precision + sensibilidad) > 0) {
  2 * precision * sensibilidad / (precision + sensibilidad)
} else NA_real_

# AUC ROC en la muestra de prueba
roc_obj <- roc(response = prueba$Abandono, predictor = prueba$Probabilidad,
               levels = c(0, 1), direction = "<", quiet = TRUE)
auc_val <- as.numeric(auc(roc_obj))

tabla_evaluacion <- tibble(
  Indicador = c("Exactitud", "Sensibilidad", "Especificidad",
                "Precision", "F1", "AUC ROC"),
  Valor = c(exactitud, sensibilidad, especificidad, precision, f1, auc_val)
)
knitr::kable(tabla_evaluacion %>% mutate(Porcentaje = round(Valor * 100, 1)), digits = 3, capt
```

**Tabla 10:** Indicadores de clasificación en prueba

| Indicador | Valor | Porcentaje |
|---|---|---|
| Exactitud | 0.815 | 81.5 |
| Sensibilidad | 0.201 | 20.1 |
| Especificidad | 0.972 | 97.2 |
| Precision | 0.651 | 65.1 |
| F1 | 0.307 | 30.7 |
| AUC ROC | 0.751 | 75.1 |

**Lectura clave:** la exactitud mide el porcentaje de clasificaciones correctas; la sensibili-

dad mide la detección de abandonos reales; la especificidad mide la detección de permanencias reales. La curva ROC y su AUC resumen discriminación a través de distintos umbrales.

En la muestra de prueba, la exactitud fue **81.5 %**, la sensibilidad **20.1 %**, la especificidad **97.2 %** y el **AUC 0.751**.

### 10.1. Matriz de confusión en prueba

```
# Grafica 7: matriz de confusion
matriz_grafica <- as.data.frame(matriz)
g7 <- ggplot(matriz_grafica, aes(x = Predicho, y = Real, fill = Freq)) +
  geom_tile(color = "white", linewidth = 1) +
  geom_text(aes(label = Freq), size = 7, fontface = "bold") +
  scale_fill_gradient(low = "#F7ECFC", high = "#70218A") +
  scale_y_discrete(limits = rev(c("0", "1"))) +
  labs(title = "Matriz de confusion: datos de prueba",
       subtitle = "0 = permanece; 1 = abandona | Umbral 0,50",
       x = "Predicho", y = "Real", fill = "Clientes") +
  theme_minimal(base_size = 13)
print(g7)
```

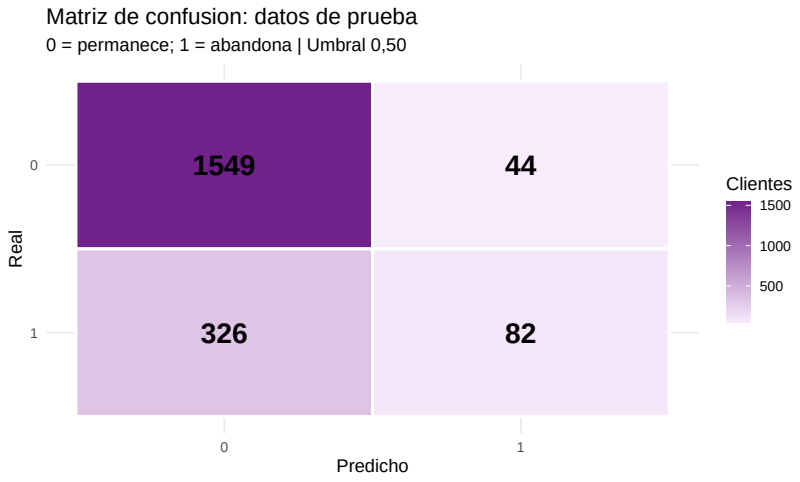



**Figura 7:** Matriz de confusión en prueba

## 10.2. Curva ROC en prueba

```
# Grafica 8: curva ROC
datos_roc <- tibble(
  Tasa_FP = 1 - roc_obj$specificities,
  Sensibilidad = roc_obj$sensitivities
)
g8 <- ggplot(datos_roc, aes(x = Tasa_FP, y = Sensibilidad)) +
  geom_abline(slope = 1, intercept = 0, linetype = "dashed", color = "grey60") +
  geom_line(color = "#70218A", linewidth = 1.2) +
  coord_equal() +
  labs(title = "Curva ROC del modelo en datos de prueba",
       subtitle = paste0("AUC = ", round(auc_val, 3)),
       x = "Tasa de falsos positivos (1 - especificidad)",
       y = "Sensibilidad") +
  theme_minimal(base_size = 12)
print(g8)
```

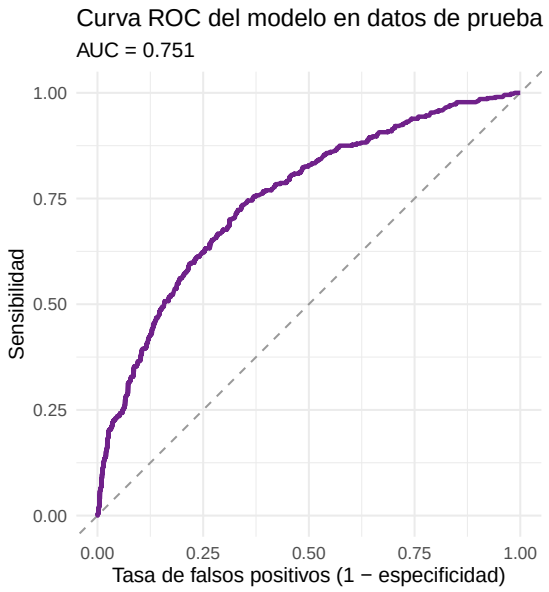



**Figura 8:** Curva ROC en prueba

### 10.3. Indicadores de clasificación en prueba

```
# Grafica 9: indicadores del modelo en datos de prueba
g9 <- tabla_evaluacion %>%
  filter(Indicador != "AUC ROC") %>%
  ggplot(aes(x = reorder(Indicador, Valor), y = Valor)) +
  geom_col(fill = "#F47721", width = .65) +
  geom_text(aes(label = percent(Valor, accuracy = .1)), hjust = -0.1, size = 4.5) +
  coord_flip() +
  scale_y_continuous(limits = c(0, 1.1), labels = percent) +
  labs(title = "Indicadores de clasificacion en datos de prueba",
       subtitle = "El porcentaje de exactitud no equivale a sensibilidad",
       x = NULL, y = "Porcentaje") +
  theme_minimal(base_size = 12)
print(g9)
```

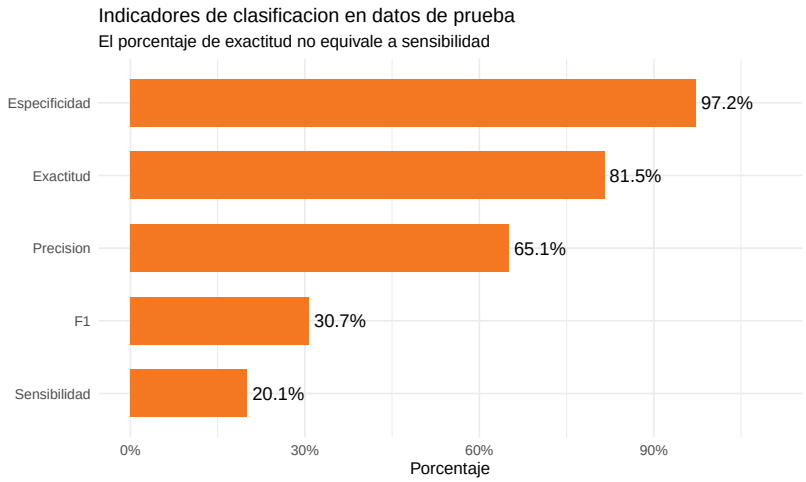



**Figura 9:** Indicadores de clasificación en prueba

## 11. Conclusiones y proyección

El modelo permite relacionar la edad, el saldo, el estado de actividad y el país con los odds de abandono. La evaluación con datos separados muestra resultados más informativos

que evaluar el mismo conjunto utilizado en el ajuste.

**Limitaciones:** se realiza una sola partición entrenamiento/prueba; el umbral de 0,50 no fue optimizado; las observaciones del dataset no permiten inferir causalidad ni garantizar resultados en otro banco. En un trabajo posterior puede evaluarse la selección del umbral mediante validación cruzada **dentro del entrenamiento**, reservando la prueba para la evaluación final.

**Aporte del proyecto de aula:** aprender a preparar datos, ajustar e interpretar un modelo estadístico, evaluar su desempeño y comunicar resultados mediant