Tipos de vino mediante regresión logística multinomial

Silvia Katerin Angel Camargo

06 de noviembre de 2026

Índice

1. Propósito del informe **2**

2. Librerías y ubicación de los archivos **3**

3. Importación y preparación de los datos **5**

4. Análisis exploratorio **9**

4.1. Distribución general de las clases 12

4.2. Alcohol por clase 13

4.3. Intensidad del color por clase 14

4.4. Ácido málico por clase 15

5. Partición estratificada: entrenamiento y prueba **16**

6. Modelo logístico multinomial **17**

7. Significancia y odds ratios **20**

8. Evaluación del ajuste en entrenamiento **23**

9. Probabilidades estimadas según perfiles **25**

10. Evaluación con datos de prueba **27**

10.1. Matriz de confusión en prueba 27

10.2. Sensibilidad y especificidad por clase 30

10.3. Curvas ROC en prueba 33

10.4. Comparación de umbrales de clasificación 35

11. Estabilidad del modelo **40**

12. Conclusiones y proyección **45**

13. Comparación final de los modelos **46**

1. Propósito del informe

Este documento muestra cómo integrar **explicaciones, código de R, tablas, gráficos e interpretaciones** en un solo informe reproducible usando R Markdown y RStudio. El análisis usa un conjunto de datos didáctico de tipos de vino (*Wine*, repositorio UCI). No representa una validación en una empresa vinícola real.

Pregunta: ¿Cómo se relacionan el contenido de alcohol, el ácido málico y la intensidad del color con la probabilidad de que un vino pertenezca a la clase 2 o a la clase 3, en lugar de a la clase 1?

Variable respuesta: `Clase` (1, 2 o 3), con la clase 1 como categoría de referencia.

Evaluación: además de la exactitud, se calculan la **sensibilidad** y la **especificidad** de cada clase (clase contra el resto), las curvas ROC y una **comparación de umbrales de clasificación**.

2. Librerías y ubicación de los archivos

Antes de compilar el informe, guarde `wine.data` en la **misma carpeta** que este `.Rmd`. Si el archivo no está, el código lo descarga desde UCI (requiere conexión a internet). La ruta relativa facilita compartir el proyecto con otros estudiantes sin modificar el nombre de usuario del computador.

```
# Se instalan solo los paquetes que falten
paquetes <- c("ggplot2", "dplyr", "nnet", "knitr", "pROC", "scales")
faltan <- setdiff(paquetes, rownames(installed.packages()))
if (length(faltan) > 0) install.packages(faltan)

library(ggplot2)  # Gráficos
library(dplyr)    # Manipulación de datos
library(nnet)     # Regresión logística multinomial
library(knitr)    # Presentación de tablas
library(pROC)     # Curvas ROC y AUC
library(scales)   # Formato de porcentajes

set.seed(2026)    # Reproducibilidad de la partición
```

Se definen también algunas funciones auxiliares: redactan porcentajes y p-valores en el texto, hacen la partición estratificada y calculan los indicadores de clasificación.

```
# Redacción de los resultados en el texto
efecto <- function(o) {
  ifelse(o >= 2, paste0("se multiplican por ", sprintf("%.2f", o)),
  ifelse(o >= 1, paste0("aumentan en ", sprintf("%.1f", (o - 1) * 100), "%"),
                 paste0("disminuyen en ", sprintf("%.1f", (1 - o) * 100), "%")))
}
fp   <- function(p) ifelse(p < 0.001, "< 0.001", sprintf("%.3f", p))
```

```r
cap1 <- function(x) paste0(toupper(substr(x, 1, 1)), substr(x, 2, nchar(x)))

nombre_var <- c(Alcohol = "Alcohol", Acido_Malico = "Ácido málico",
                Intensidad_Color = "Intensidad del color")
unidad_var <- c(Alcohol = "por cada punto adicional de alcohol",
                Acido_Malico = "por cada unidad adicional de ácido málico",
                Intensidad_Color = "por cada unidad adicional de intensidad del color")
colores_clase <- c("1" = "#70218A", "2" = "#F47721", "3" = "#1B9E9E")

# Partición estratificada por clase (usa sample.int para evitar el problema
# de sample() cuando solo hay un elemento)
particion_estratificada <- function(datos, prop = 0.70) {
  indices <- split(seq_len(nrow(datos)), datos$Clase)
  seleccion <- unlist(lapply(indices, function(i) {
    i[sample.int(length(i), size = round(prop * length(i)))]
  }), use.names = FALSE)
  list(entrenamiento = datos[seleccion, ], prueba = datos[-seleccion, ])
}

# Sensibilidad, especificidad y otros indicadores para una clase contra el
# resto, dado un umbral sobre la probabilidad estimada de esa clase
metricas_umbral <- function(real, prob, umbral) {
  pred <- prob >= umbral
  VP <- sum(pred & real);  FN <- sum(!pred & real)
  FP <- sum(pred & !real); VN <- sum(!pred & !real)
  sens <- if ((VP + FN) > 0) VP / (VP + FN) else NA_real_
  espe <- if ((VN + FP) > 0) VN / (VN + FP) else NA_real_
  prec <- if ((VP + FP) > 0) VP / (VP + FP) else NA_real_
  data.frame(Umbral = umbral, VP = VP, FN = FN, FP = FP, VN = VN,
```

```
             Sensibilidad = sens, Especificidad = espe, Precision = prec,
             Youden = sens + espe - 1)
}

# Indicadores de cada clase contra el resto a partir de la matriz de confusión
metricas_por_clase <- function(matriz) {
  do.call(rbind, lapply(rownames(matriz), function(k) {
    VP <- unname(matriz[k, k])
    FN <- sum(matriz[k, ]) - VP
    FP <- sum(matriz[, k]) - VP
    VN <- sum(matriz) - VP - FN - FP
    sens <- if ((VP + FN) > 0) VP / (VP + FN) else NA_real_
    espe <- if ((VN + FP) > 0) VN / (VN + FP) else NA_real_
    prec <- if ((VP + FP) > 0) VP / (VP + FP) else NA_real_
    f1 <- if (is.finite(prec) && is.finite(sens) && (prec + sens) > 0) {
      2 * prec * sens / (prec + sens)
    } else NA_real_
    data.frame(Clase = k, Sensibilidad = sens, Especificidad = espe,
               Precision = prec, F1 = f1)
  }))
}
```

3. Importación y preparación de los datos

Nombramos las columnas en español, definimos la variable respuesta como factor, revisamos valores faltantes y registros repetidos, y conservamos las variables del modelo.

```
# Se usa el archivo local "wine.data" si existe; si no, se lee desde UCI.
url_vino <- paste0("https://archive.ics.uci.edu/ml/",
```

```
                  "machine-learning-databases/wine/wine.data")
fuente_vino <- if (file.exists("wine.data")) "wine.data" else url_vino
Vinos <- read.csv(fuente_vino, header = FALSE)
stopifnot(ncol(Vinos) == 14)

names(Vinos) <- c(
  "Clase", "Alcohol", "Acido_Malico", "Ceniza", "Alcalinidad_Ceniza",
  "Magnesio", "Fenoles_Totales", "Flavonoides", "Fenoles_No_Flavonoides",
  "Proantocianinas", "Intensidad_Color", "Matiz", "OD280_OD315", "Prolina"
)

dim(Vinos)
```

```
## [1] 178  14
```

```
str(Vinos)
```

```
## 'data.frame':    178 obs. of  14 variables:
##  $ Clase                 : int  1 1 1 1 1 1 1 1 1 1 ...
##  $ Alcohol               : num  14.2 13.2 13.2 14.4 13.2 ...
##  $ Acido_Malico          : num  1.71 1.78 2.36 1.95 2.59 1.76 1.87 2.15 1.64 1.35 ...
##  $ Ceniza                : num  2.43 2.14 2.67 2.5 2.87 2.45 2.45 2.61 2.17 2.27 ...
##  $ Alcalinidad_Ceniza    : num  15.6 11.2 18.6 16.8 21 15.2 14.6 17.6 14 16 ...
##  $ Magnesio              : int  127 100 101 113 118 112 96 121 97 98 ...
##  $ Fenoles_Totales       : num  2.8 2.65 2.8 3.85 2.8 3.27 2.5 2.6 2.8 2.98 ...
##  $ Flavonoides           : num  3.06 2.76 3.24 3.49 2.69 3.39 2.52 2.51 2.98 3.15 ...
##  $ Fenoles_No_Flavonoides: num  0.28 0.26 0.3 0.24 0.39 0.34 0.3 0.31 0.29 0.22 ...
##  $ Proantocianinas       : num  2.29 1.28 2.81 2.18 1.82 1.97 1.98 1.25 1.98 1.85 ...
##  $ Intensidad_Color      : num  5.64 4.38 5.68 7.8 4.32 6.75 5.25 5.05 5.2 7.22 ...
##  $ Matiz                 : num  1.04 1.05 1.03 0.86 1.04 1.05 1.02 1.06 1.08 1.01 ...
```

```
##  $ OD280_OD315           : num  3.92 3.4 3.17 3.45 2.93 2.85 3.58 3.58 2.85 3.55 ...
##  $ Prolina               : int  1065 1050 1185 1480 735 1450 1290 1295 1045 1045 ...
```

```
summary(Vinos)
```

```
##      Clase          Alcohol       Acido_Malico       Ceniza
##  Min.   :1.000   Min.   :11.03   Min.   :0.740   Min.   :1.360
##  1st Qu.:1.000   1st Qu.:12.36   1st Qu.:1.603   1st Qu.:2.210
##  Median :2.000   Median :13.05   Median :1.865   Median :2.360
##  Mean   :1.938   Mean   :13.00   Mean   :2.336   Mean   :2.367
##  3rd Qu.:3.000   3rd Qu.:13.68   3rd Qu.:3.083   3rd Qu.:2.558
##  Max.   :3.000   Max.   :14.83   Max.   :5.800   Max.   :3.230
##  Alcalinidad_Ceniza    Magnesio      Fenoles_Totales  Flavonoides
##  Min.   :10.60      Min.   : 70.00   Min.   :0.980   Min.   :0.340
##  1st Qu.:17.20      1st Qu.: 88.00   1st Qu.:1.742   1st Qu.:1.205
##  Median :19.50      Median : 98.00   Median :2.355   Median :2.135
##  Mean   :19.49      Mean   : 99.74   Mean   :2.295   Mean   :2.029
##  3rd Qu.:21.50      3rd Qu.:107.00   3rd Qu.:2.800   3rd Qu.:2.875
##  Max.   :30.00      Max.   :162.00   Max.   :3.880   Max.   :5.080
##  Fenoles_No_Flavonoides Proantocianinas Intensidad_Color
##  Min.   :0.1300         Min.   :0.410   Min.   : 1.280
##  1st Qu.:0.2700         1st Qu.:1.250   1st Qu.: 3.220
##  Median :0.3400         Median :1.555   Median : 4.690
##  Mean   :0.3619         Mean   :1.591   Mean   : 5.058
##  3rd Qu.:0.4375         3rd Qu.:1.950   3rd Qu.: 6.200
##  Max.   :0.6600         Max.   :3.580   Max.   :13.000
##      Matiz         OD280_OD315       Prolina
##  Min.   :0.4800   Min.   :1.270   Min.   : 278.0
##  1st Qu.:0.7825   1st Qu.:1.938   1st Qu.: 500.5
##  Median :0.9650   Median :2.780   Median : 673.5
```

```
##  Mean   :0.9574   Mean   :2.612   Mean   : 746.9
##  3rd Qu.:1.1200   3rd Qu.:3.170   3rd Qu.: 985.0
##  Max.   :1.7100   Max.   :4.000   Max.   :1680.0
```

```r
# Revisar faltantes y registros repetidos
colSums(is.na(Vinos))
```

```
##                   Clase                 Alcohol           Acido_Malico
##                       0                       0                       0
##                  Ceniza     Alcalinidad_Ceniza               Magnesio
##                       0                       0                       0
##        Fenoles_Totales            Flavonoides Fenoles_No_Flavonoides
##                       0                       0                       0
##        Proantocianinas       Intensidad_Color                   Matiz
##                       0                       0                       0
##            OD280_OD315                Prolina
##                       0                       0
```

```r
sum(duplicated(Vinos))
```

```
## [1] 0
```

```r
# Tres clases nominales; la clase 1 es la categoría de referencia
Vinos$Clase <- factor(Vinos$Clase, levels = c(1, 2, 3))

# Datos completos para las variables del modelo
Datos_modelo <- na.omit(Vinos[, c("Clase", "Alcohol", "Acido_Malico",
                                  "Intensidad_Color")])
rownames(Datos_modelo) <- NULL
stopifnot(nlevels(Datos_modelo$Clase) == 3,
          all(Datos_modelo$Clase %in% c("1", "2", "3")))
```

```r
estructura_tabla <- data.frame(
  Variable = names(Datos_modelo),
  Tipo_Dato = sapply(Datos_modelo, function(x) class(x)[1]),
  Valores_Ejemplo = sapply(Datos_modelo, function(x)
    paste(head(na.omit(as.character(x)), 3), collapse = ", "))
)
kable(estructura_tabla, row.names = FALSE,
      col.names = c("Variable", "Tipo de dato", "Valores de ejemplo"),
      caption = "Variables utilizadas en el modelo")
```

Tabla 1: Variables utilizadas en el modelo

Variable	Tipo de dato	Valores de ejemplo
Clase	factor	1, 1, 1
Alcohol	numeric	14.23, 13.2, 13.16
Acido_Malico	numeric	1.71, 1.78, 2.36
Intensidad_Color	numeric	5.64, 4.38, 5.68

El conjunto limpio contiene **178 registros** y **4 variables** para la fase de modelado. El total de valores faltantes en la base original es 0.

4. Análisis exploratorio

```r
# Distribución de la respuesta
tabla_clase <- Datos_modelo %>%
  count(Clase) %>%
  mutate(Porcentaje = round(100 * n / sum(n), 1))
```

```r
kable(tabla_clase, col.names = c("Clase", "Vinos", "Porcentaje"),
      caption = "Distribución de las clases de vino")
```

Tabla 2: Distribución de las clases de vino

Clase	Vinos	Porcentaje
1	59	33.1
2	71	39.9
3	48	27.0

```r
# Resumen descriptivo de los predictores, por clase
tabla_resumen <- Datos_modelo %>%
  group_by(Clase) %>%
  summarise(Alcohol_media = round(mean(Alcohol), 2),
            Alcohol_DE    = round(sd(Alcohol), 2),
            Acido_media   = round(mean(Acido_Malico), 2),
            Acido_DE      = round(sd(Acido_Malico), 2),
            Color_media   = round(mean(Intensidad_Color), 2),
            Color_DE      = round(sd(Intensidad_Color), 2),
            .groups = "drop")
kable(tabla_resumen,
      col.names = c("Clase", "Alc. media", "Alc. DE", "Málico media",
                    "Málico DE", "Color media", "Color DE"),
      caption = "Media y desviación estándar (DE) de los predictores por clase")
```

Tabla 3: Media y desviación estándar (DE) de los predictores por clase

Clase	Alc. media	Alc. DE	Málico media	Málico DE	Color media	Color DE
1	13.74	0.46	2.01	0.69	5.53	1.24
2	12.28	0.54	1.93	1.02	3.09	0.92

Clase	Alc. media	Alc. DE	Málico media	Málico DE	Color media	Color DE
3	13.15	0.53	3.33	1.09	7.40	2.31

```
summary(Datos_modelo[, c("Alcohol", "Acido_Malico", "Intensidad_Color")])
```

```
##     Alcohol       Acido_Malico   Intensidad_Color
##  Min.   :11.03   Min.   :0.740   Min.   : 1.280
##  1st Qu.:12.36   1st Qu.:1.603   1st Qu.: 3.220
##  Median :13.05   Median :1.865   Median : 4.690
##  Mean   :13.00   Mean   :2.336   Mean   : 5.058
##  3rd Qu.:13.68   3rd Qu.:3.083   3rd Qu.: 6.200
##  Max.   :14.83   Max.   :5.800   Max.   :13.000
```

```
# Frases construidas con los resultados (se actualizan si cambian los datos)
describir <- function(v, nombre) {
  i_max <- which.max(v); i_min <- which.min(v)
  sprintf("%s es más alto en la clase %s (media %.2f) y más bajo en la clase %s (media %.2f)",
          nombre, as.character(tabla_resumen$Clase[i_max]), v[i_max],
          as.character(tabla_resumen$Clase[i_min]), v[i_min])
}
txt_alcohol <- describir(tabla_resumen$Alcohol_media, "El contenido de alcohol")
txt_malico  <- describir(tabla_resumen$Acido_media,   "El ácido málico")
txt_color   <- describir(tabla_resumen$Color_media,   "La intensidad del color")
txt_clases  <- paste(sprintf("clase %s: %.1f %%",
                             as.character(tabla_clase$Clase),
                             tabla_clase$Porcentaje), collapse = "; ")
razon_clases <- max(tabla_clase$n) / min(tabla_clase$n)
```

Interpretación: la base contiene 178 vinos repartidos así: clase 1: 33.1 %; clase 2: 39.9 %; clase 3: 27.0 %. La clase más grande tiene 1.48 veces los vinos de la más pequeña. El

contenido de alcohol es más alto en la clase 1 (media 13.74) y más bajo en la clase 2 (media 12.28). El ácido málico es más alto en la clase 3 (media 3.33) y más bajo en la clase 2 (media 1.93). La intensidad del color es más alto en la clase 3 (media 7.40) y más bajo en la clase 2 (media 3.09). Las tablas y gráficas permiten examinar diferencias descriptivas, sin atribuirles por sí solas causalidad. Los predictores se escogieron por ser interpretables para una empresa vinícola y por mostrar diferencias entre clases en esta exploración.

4.1. Distribución general de las clases

```
g1 <- ggplot(tabla_clase, aes(x = Clase, y = Porcentaje, fill = Clase)) +
  geom_col(width = .55, show.legend = FALSE) +
  geom_text(aes(label = paste0(Porcentaje, "%")), vjust = -.4, size = 5) +
  scale_fill_manual(values = colores_clase) +
  scale_y_continuous(limits = c(0, max(tabla_clase$Porcentaje) + 10)) +
  labs(title = "¿Qué porcentaje de vinos hay en cada clase?",
       x = "Clase de vino", y = "Porcentaje de vinos") +
  theme_minimal(base_size = 13)
print(g1)
```

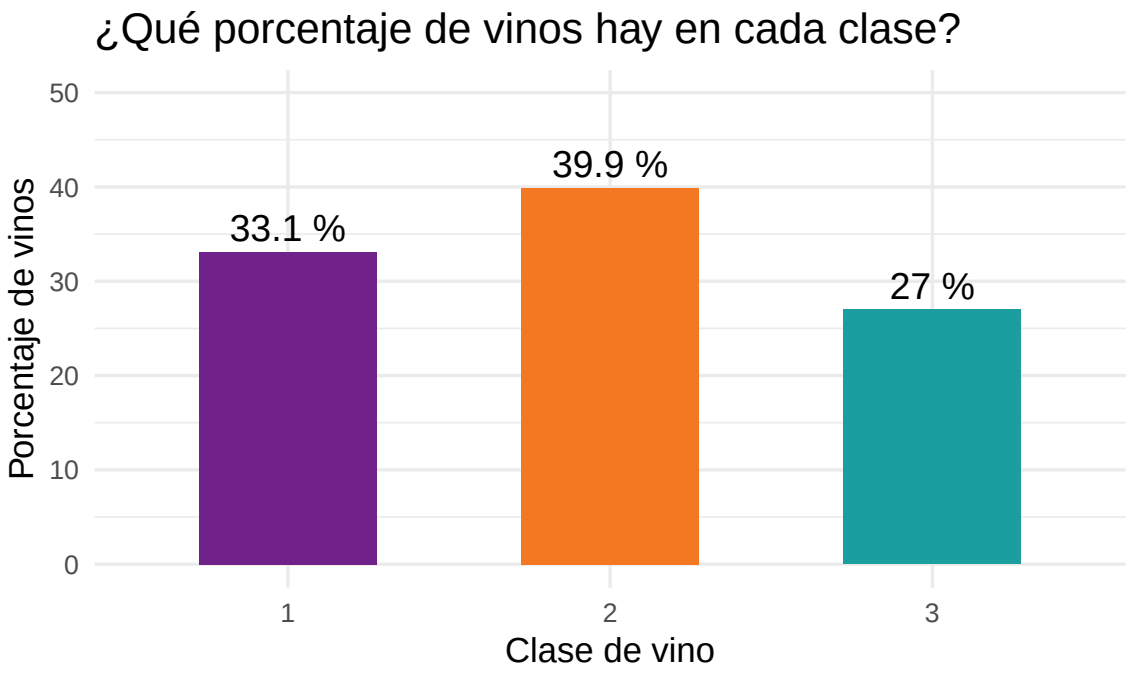


Figura 1: Distribución general de las clases de vino.

4.2. Alcohol por clase

```
grafica_caja <- function(variable, etiqueta) {
  ggplot(Datos_modelo, aes(x = Clase, y = .data[[variable]], fill = Clase)) +
    geom_boxplot(alpha = .85, show.legend = FALSE) +
    scale_fill_manual(values = colores_clase) +
    labs(title = paste(etiqueta, "según la clase de vino"),
         x = "Clase de vino", y = etiqueta) +
    theme_minimal(base_size = 13)
}
print(grafica_caja("Alcohol", "Alcohol"))
```

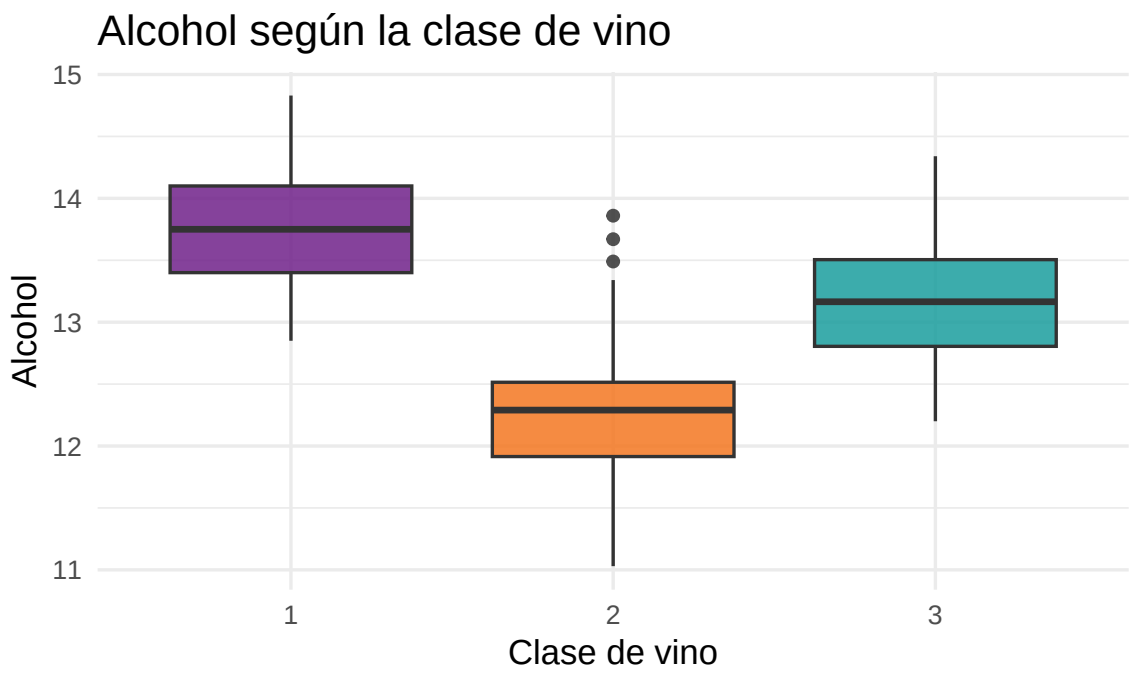


Figura 2: Contenido de alcohol por clase de vino.

4.3. Intensidad del color por clase

```
print(grafica_caja("Intensidad_Color", "Intensidad del color"))
```

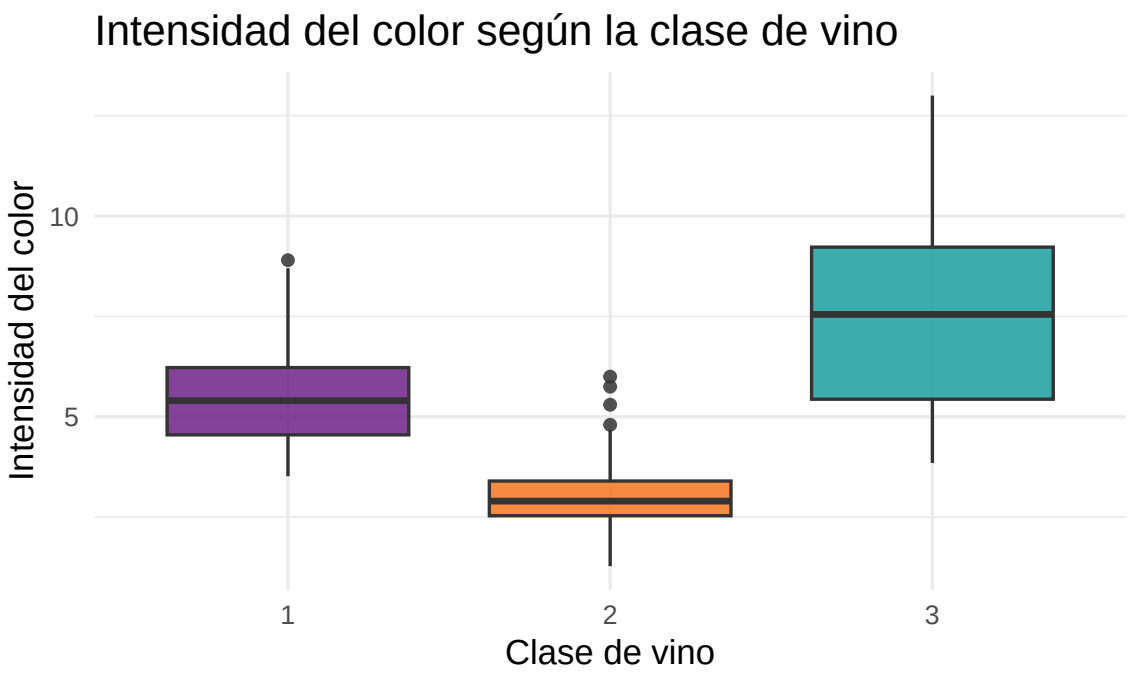


Figura 3: Intensidad del color por clase de vino.

4.4. Ácido málico por clase

```
print(grafica_caja("Acido_Malico", "Ácido málico"))
```

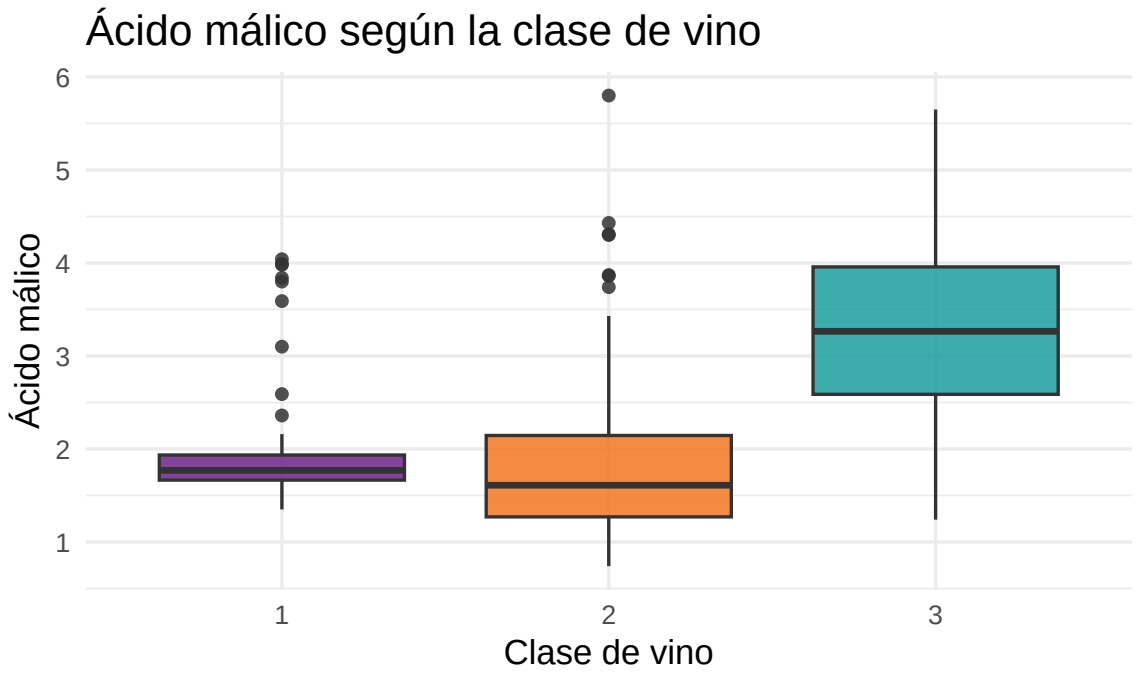


Figura 4: Ácido málico por clase de vino.

5. Partición estratificada: entrenamiento y prueba

Reservamos aproximadamente el 30 % de los registros para **prueba**. La estratificación mantiene una proporción semejante de cada clase en ambos subconjuntos. La muestra de prueba no se usa para ajustar el modelo ni para elegir umbrales.

```
set.seed(2026)
particion <- particion_estratificada(Datos_modelo, prop = 0.70)
entrenamiento <- particion$entrenamiento
prueba <- particion$prueba
cat("Entrenamiento:", nrow(entrenamiento), "filas\n")
```

```
## Entrenamiento: 125 filas
```

```r
cat("Prueba:", nrow(prueba), "filas\n")
```

```
## Prueba: 53 filas
```

```r
# Confirmar que la proporción de cada clase es similar
comp_prop <- data.frame(
  Clase = levels(Datos_modelo$Clase),
  Entrenamiento = round(100 * as.numeric(prop.table(table(entrenamiento$Clase))), 1),
  Prueba = round(100 * as.numeric(prop.table(table(prueba$Clase))), 1)
)
kable(comp_prop, col.names = c("Clase", "Entrenamiento (porcentaje)",
                               "Prueba (porcentaje)"),
      caption = "Proporción de cada clase en entrenamiento y prueba")
```

Tabla 4: Proporción de cada clase en entrenamiento y prueba

Clase	Entrenamiento (porcentaje)	Prueba (porcentaje)
1	32.8	34.0
2	40.0	39.6
3	27.2	26.4

El entrenamiento contiene **125** registros y la prueba **53**.

6. Modelo logístico multinomial

Como la respuesta tiene tres categorías nominales sin orden, utilizamos una **regresión logística multinomial** con la clase 1 como referencia. Se estiman dos ecuaciones, una para la clase 2 y otra para la clase 3:

$$\log\left(\frac{P(\text{Clase}=k)}{P(\text{Clase}=1)}\right) = \beta_{0k} + \beta_{1k}\,\text{Alcohol} + \beta_{2k}\,\text{Málico} + \beta_{3k}\,\text{Color}, \qquad k = 2, 3.$$

Cada coeficiente compara la clase 2 (o la 3) **contra la clase 1**.

```
# Ajuste del modelo (solo con los datos de entrenamiento)
modelo_multi <- multinom(
  Clase ~ Alcohol + Acido_Malico + Intensidad_Color,
  data = entrenamiento,
  trace = FALSE,
  maxit = 500
)
cat("Convergencia (0 = el algoritmo convergió):", modelo_multi$convergence, "\n")
```

```
## Convergencia (0 = el algoritmo convergió): 0
```

```
summary(modelo_multi)
```

```
## Call:
## multinom(formula = Clase ~ Alcohol + Acido_Malico + Intensidad_Color,
##     data = entrenamiento, trace = FALSE, maxit = 500)
##
## Coefficients:
##   (Intercept)   Alcohol Acido_Malico Intensidad_Color
## 2    58.13897 -3.940983    0.1952227        -1.634043
## 3    36.64947 -4.045499    2.4764629         1.767030
##
## Std. Errors:
##   (Intercept)  Alcohol Acido_Malico Intensidad_Color
## 2    15.60617 1.164960    0.5022495        0.5748324
```

```
## 3    13.16135 1.150039    0.6968941        0.5831694
##
## Residual Deviance: 59.40435
## AIC: 75.40435
```

```r
# Coeficientes, errores estándar, z y p-valores (prueba de Wald)
co <- coef(modelo_multi)
se <- summary(modelo_multi)$standard.errors
z  <- co / se
pv <- 2 * pnorm(-abs(z))

variables <- setdiff(colnames(co), "(Intercept)")
dp <- sapply(entrenamiento[, variables], sd)   # desviación estándar de cada predictor

tab_multi <- do.call(rbind, lapply(rownames(co), function(k) {
  data.frame(
    Clase_comp  = k,
    Comparacion = paste("Clase", k, "vs 1"),
    Variable    = variables,
    Coeficiente = co[k, variables],
    Error_est   = se[k, variables],
    z           = z[k, variables],
    Valor_p     = pv[k, variables],
    OR          = exp(co[k, variables]),
    IC95_inf    = exp(co[k, variables] - 1.96 * se[k, variables]),
    IC95_sup    = exp(co[k, variables] + 1.96 * se[k, variables]),
    OR_por_DE   = exp(co[k, variables] * dp[variables]),
    row.names   = NULL
  )
}))
```

```r
# El intercepto no se interpreta, por eso se omite de la tabla
tabla_coef <- tab_multi[, c("Comparacion", "Variable", "Coeficiente",
                            "Error_est", "z", "Valor_p")]
tabla_coef$Variable <- unname(nombre_var[tabla_coef$Variable])
tabla_coef$Valor_p  <- fp(tabla_coef$Valor_p)
kable(tabla_coef, digits = 3, row.names = FALSE,
      col.names = c("Comparación", "Variable", "Coeficiente", "Error est.",
                    "z", "Valor p"),
      caption = "Coeficientes del modelo multinomial frente a la clase 1")
```

Tabla 5: Coeficientes del modelo multinomial frente a la clase 1

Comparación	Variable	Coeficiente	Error est.	z	Valor p
Clase 2 vs 1	Alcohol	-3.941	1.165	-3.383	< 0.001
Clase 2 vs 1	Ácido málico	0.195	0.502	0.389	0.698
Clase 2 vs 1	Intensidad del color	-1.634	0.575	-2.843	0.004
Clase 3 vs 1	Alcohol	-4.045	1.150	-3.518	< 0.001
Clase 3 vs 1	Ácido málico	2.476	0.697	3.554	< 0.001
Clase 3 vs 1	Intensidad del color	1.767	0.583	3.030	0.002

7. Significancia y odds ratios

Para cada coeficiente, el **odds ratio (OR)** es su exponencial. En el modelo multinomial compara los odds de pertenecer a la clase indicada, en lugar de la clase 1, por cada aumento de una unidad del predictor y manteniendo los demás constantes. Como los predictores tienen escalas distintas, se agrega el **OR por desviación estándar**, que permite comparar la fuerza de las asociaciones entre variables.

```r
tabla_or <- tab_multi[, c("Comparacion", "Variable", "OR", "IC95_inf",
                          "IC95_sup", "OR_por_DE", "Valor_p")]
tabla_or$Variable <- unname(nombre_var[tabla_or$Variable])
tabla_or$Valor_p  <- fp(tabla_or$Valor_p)
kable(tabla_or, digits = 3, row.names = FALSE,
      col.names = c("Comparación", "Variable", "OR", "IC95 inf.",
                    "IC95 sup.", "OR por DE", "Valor p"),
      caption = "Odds ratios ajustados e intervalos de confianza (entrenamiento)")
```

Tabla 6: Odds ratios ajustados e intervalos de confianza (entrenamiento)

Comparación	Variable	OR	IC95 inf.	IC95 sup.	OR por DE	Valor p
Clase 2 vs 1	Alcohol	0.019	0.002	0.191	0.043	< 0.001
Clase 2 vs 1	Ácido málico	1.216	0.454	3.253	1.238	0.698
Clase 2 vs 1	Intensidad del color	0.195	0.063	0.602	0.018	0.004
Clase 3 vs 1	Alcohol	0.018	0.002	0.167	0.039	< 0.001
Clase 3 vs 1	Ácido málico	11.899	3.036	46.636	15.036	< 0.001
Clase 3 vs 1	Intensidad del color	5.853	1.866	18.358	75.709	0.002

- *Alcohol, clase 2 vs 1:* coeficiente -3.941, OR 0.019 (IC del 95 %: 0.002 a 0.191; p < 0.001). Por cada punto adicional de alcohol, los odds de ser de la clase 2 en lugar de la clase 1 disminuyen en 98.1 %. La asociación es significativa a un nivel de 5 %.
- *Ácido málico, clase 2 vs 1:* coeficiente 0.195, OR 1.216 (IC del 95 %: 0.454 a 3.253; p 0.698). Por cada unidad adicional de ácido málico, los odds de ser de la clase 2 en lugar de la clase 1 aumentan en 21.6 %. La asociación no es significativa a un nivel de 5 %.
- *Intensidad del color, clase 2 vs 1:* coeficiente -1.634, OR 0.195 (IC del 95 %: 0.063 a 0.602; p 0.004). Por cada unidad adicional de intensidad del color, los odds de ser de la clase 2 en lugar de la clase 1 disminuyen en 80.5 %. La asociación es significativa a un nivel de 5 %.

- *Alcohol, clase 3 vs 1:* coeficiente -4.045, OR 0.018 (IC del 95 %: 0.002 a 0.167; p < 0.001). Por cada punto adicional de alcohol, los odds de ser de la clase 3 en lugar de la clase 1 disminuyen en 98.2 %. La asociación es significativa a un nivel de 5 %.
- *Ácido málico, clase 3 vs 1:* coeficiente 2.476, OR 11.899 (IC del 95 %: 3.036 a 46.636; p < 0.001). Por cada unidad adicional de ácido málico, los odds de ser de la clase 3 en lugar de la clase 1 se multiplican por 11.90. La asociación es significativa a un nivel de 5 %.
- *Intensidad del color, clase 3 vs 1:* coeficiente 1.767, OR 5.853 (IC del 95 %: 1.866 a 18.358; p 0.002). Por cada unidad adicional de intensidad del color, los odds de ser de la clase 3 en lugar de la clase 1 se multiplican por 5.85. La asociación es significativa a un nivel de 5 %.

Un OR mayor que 1 representa mayores odds de pertenecer a esa clase frente a la clase 1, y uno menor que 1, menores odds. Los coeficientes son **asociaciones**, no efectos causales.

```
etiquetas_graf <- c(Alcohol = "Alcohol (por punto)",
                    Acido_Malico = "Ácido málico (por unidad)",
                    Intensidad_Color = "Intensidad del color (por unidad)")
g5 <- tab_multi  %>%
  mutate(Etiqueta = unname(etiquetas_graf[Variable]))  %>%
  ggplot(aes(x = Etiqueta, y = OR)) +
  geom_hline(yintercept = 1, linetype = "dashed", color = "grey40") +
  geom_pointrange(aes(ymin = IC95_inf, ymax = IC95_sup),
                  color = "#70218A", linewidth = .6) +
  coord_flip() +
  scale_y_log10() +
  facet_wrap(~ Comparacion) +
  labs(title = "Factores asociados al tipo de vino",
       subtitle = "Odds ratios ajustados e IC del 95 % | Entrenamiento",
       x = NULL, y = "Odds ratio (escala logarítmica)") +
```

```
  theme_minimal(base_size = 12)

print(g5)
```

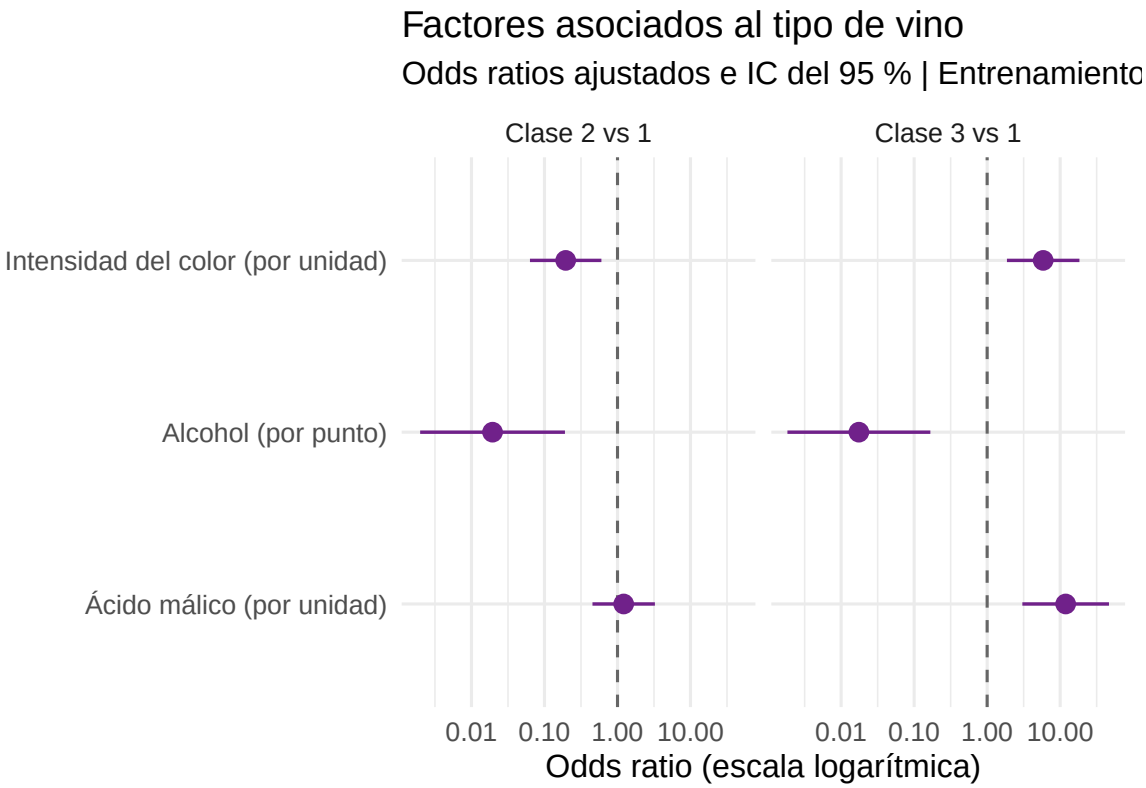


Figura 5: Odds ratios ajustados con intervalos de confianza del 95 %.

8. Evaluación del ajuste en entrenamiento

```
modelo_nulo <- multinom(Clase ~ 1, data = entrenamiento, trace = FALSE)


ll_modelo <- logLik(modelo_multi)

ll_nulo   <- logLik(modelo_nulo)

dev_nula  <- -2 * as.numeric(ll_nulo)

dev_resid <- -2 * as.numeric(ll_modelo)

aic_val   <- AIC(modelo_multi)

aic_nulo  <- AIC(modelo_nulo)
```

```r
pseudo_r2 <- 1 - as.numeric(ll_modelo) / as.numeric(ll_nulo)


# Prueba de razón de verosimilitud contra el modelo sin predictores
lr   <- dev_nula - dev_resid
gl   <- attr(ll_modelo, "df") - attr(ll_nulo, "df")
p_lr <- pchisq(lr, df = gl, lower.tail = FALSE)


tabla_ajuste <- data.frame(
  Medida = c("Devianza nula", "Devianza residual", "AIC del modelo",
             "AIC del modelo nulo", "Pseudo R2 de McFadden"),
  Valor = round(c(dev_nula, dev_resid, aic_val, aic_nulo, pseudo_r2), 3)
)
kable(tabla_ajuste, caption = "Medidas de ajuste en entrenamiento")
```

Tabla 7: Medidas de ajuste en entrenamiento

Medida	Valor
Devianza nula	271.571
Devianza residual	59.404
AIC del modelo	75.404
AIC del modelo nulo	275.571
Pseudo R2 de McFadden	0.781

La devianza y el AIC informan sobre el ajuste y permiten comparar modelos apropiados sobre los mismos datos. La prueba de razón de verosimilitud contra el modelo sin predictores da χ^2 = 212.2 con 6 grados de libertad (p < 0.001), por lo que el modelo ajusta mejor que uno sin predictores. El pseudo-R² de McFadden (0.781) **no** se interpreta como porcentaje de varianza explicada.

9. Probabilidades estimadas según perfiles

Se comparan perfiles hipotéticos con el ácido málico en su mediana y la intensidad del color recorriendo todo su rango observado, para tres niveles de alcohol (cuartiles 1, 2 y 3 del entrenamiento).

```
niveles_alcohol <- as.numeric(quantile(entrenamiento$Alcohol, c(.25, .50, .75)))
nuevos_datos <- expand.grid(
  Intensidad_Color = seq(min(entrenamiento$Intensidad_Color),
                         max(entrenamiento$Intensidad_Color), length.out = 100),
  Alcohol = niveles_alcohol,
  Acido_Malico = median(entrenamiento$Acido_Malico)
)
prob_perfil <- predict(modelo_multi, newdata = nuevos_datos, type = "probs")

perfil_largo <- do.call(rbind, lapply(colnames(prob_perfil), function(k) {
  data.frame(nuevos_datos, Clase = k, Probabilidad = prob_perfil[, k])
}))
etiq_alcohol <- sprintf("Alcohol =%.1f", perfil_largo$Alcohol)
perfil_largo$Perfil <- factor(etiq_alcohol,
                              levels = unique(sprintf("Alcohol =%.1f", niveles_alcohol)))

# Clase más probable con el color más bajo y más alto (alcohol en la mediana)
pr_med <- prob_perfil[nuevos_datos$Alcohol == niveles_alcohol[2], , drop = FALSE]
clase_baja <- colnames(pr_med)[which.max(pr_med[1, ])]
clase_alta <- colnames(pr_med)[which.max(pr_med[nrow(pr_med), ])]
```

```
g6 <- ggplot(perfil_largo, aes(x = Intensidad_Color, y = Probabilidad,
                               color = Clase)) +
  geom_line(linewidth = 1.1) +
```

```r
  facet_wrap(~ Perfil) +
  scale_color_manual(values = colores_clase) +
  scale_y_continuous(labels = percent_format(accuracy = 1), limits = c(0, 1)) +
  labs(title = "Probabilidad estimada de cada clase según el color",
       subtitle = "Ácido málico constante en la mediana",
       x = "Intensidad del color", y = "Probabilidad estimada",
       color = "Clase") +
  theme_minimal(base_size = 12) + theme(legend.position = "bottom")
print(g6)
```

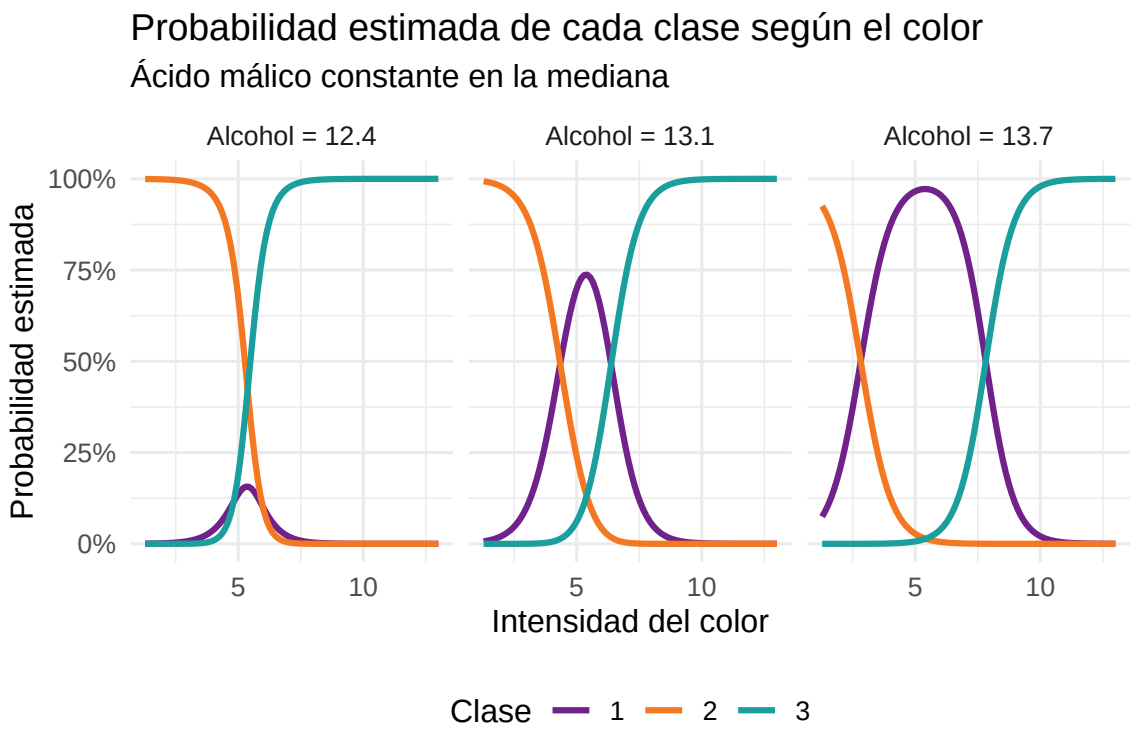


Figura 6: Probabilidad estimada de cada clase según la intensidad del color, para tres niveles de alcohol.

Con alcohol en su mediana, la clase con mayor probabilidad en el color más bajo observado es la 2 y en el color más alto es la 3. En los valores intermedios las probabilidades se reparten entre clases, que es donde se concentran los errores de clasificación.

10. Evaluación con datos de prueba

Aplicamos el modelo entrenado a observaciones no utilizadas para calcular los coeficientes. Para cada vino el modelo entrega tres probabilidades que suman 1; la **clase predicha** es la de mayor probabilidad.

```
# No se utiliza 'prueba' para ajustar coeficientes ni elegir variables.
prob_prueba <- predict(modelo_multi, newdata = prueba, type = "probs")
head(round(prob_prueba, 3))
```

```
##        1     2     3
## 1  0.998 0.001 0.001
## 6  0.989 0.000 0.011
## 7  0.998 0.001 0.000
## 11 0.991 0.002 0.008
## 14 1.000 0.000 0.000
## 16 0.751 0.001 0.248
```

```
summary(rowSums(prob_prueba))    # cada fila suma 1
```

```
##    Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##       1       1       1       1       1       1
```

```
clases <- levels(Datos_modelo$Clase)
prueba$Prediccion <- factor(colnames(prob_prueba)[max.col(prob_prueba,
                                                          ties.method = "first")],
                            levels = clases)
```

10.1. Matriz de confusión en prueba

```r
# Matriz: filas = real, columnas = predicho
matriz <- table(Real = prueba$Clase, Predicho = prueba$Prediccion)
kable(matriz, caption = "Matriz de confusión (prueba)")
```

Tabla 8: Matriz de confusión (prueba)

1	2	3
15	1	2
2	18	1
0	4	10

```r
exactitud_m <- sum(diag(matriz)) / sum(matriz)


# Exactitud de referencia: predecir siempre la clase más frecuente del entrenamiento
clase_mayor    <- names(which.max(table(entrenamiento$Clase)))
exactitud_base <- mean(prueba$Clase == clase_mayor)
```

En los 53 vinos de prueba el modelo clasifica correctamente 43, para una **exactitud de 81.1 %**. Como referencia, predecir siempre la clase más frecuente del entrenamiento (clase 2) daría una exactitud de 39.6 %.

```r
matriz_grafica <- as.data.frame(matriz)
g7 <- ggplot(matriz_grafica, aes(x = Predicho, y = Real, fill = Freq)) +
  geom_tile(color = "white", linewidth = 1) +
  geom_text(aes(label = Freq, color = Freq > max(Freq) / 2),
            size = 7, fontface = "bold") +
  scale_color_manual(values = c("TRUE" = "white", "FALSE" = "black"),
                     guide = "none") +
  scale_fill_gradient(low = "#F7ECFC", high = "#70218A") +
  scale_y_discrete(limits = rev(levels(matriz_grafica$Real))) +
```

```
  labs(title = "Matriz de confusión: datos de prueba",
       subtitle = "Clase predicha = la de mayor probabilidad",
       x = "Predicho", y = "Real", fill = "Vinos") +
  theme_minimal(base_size = 13)
print(g7)
```

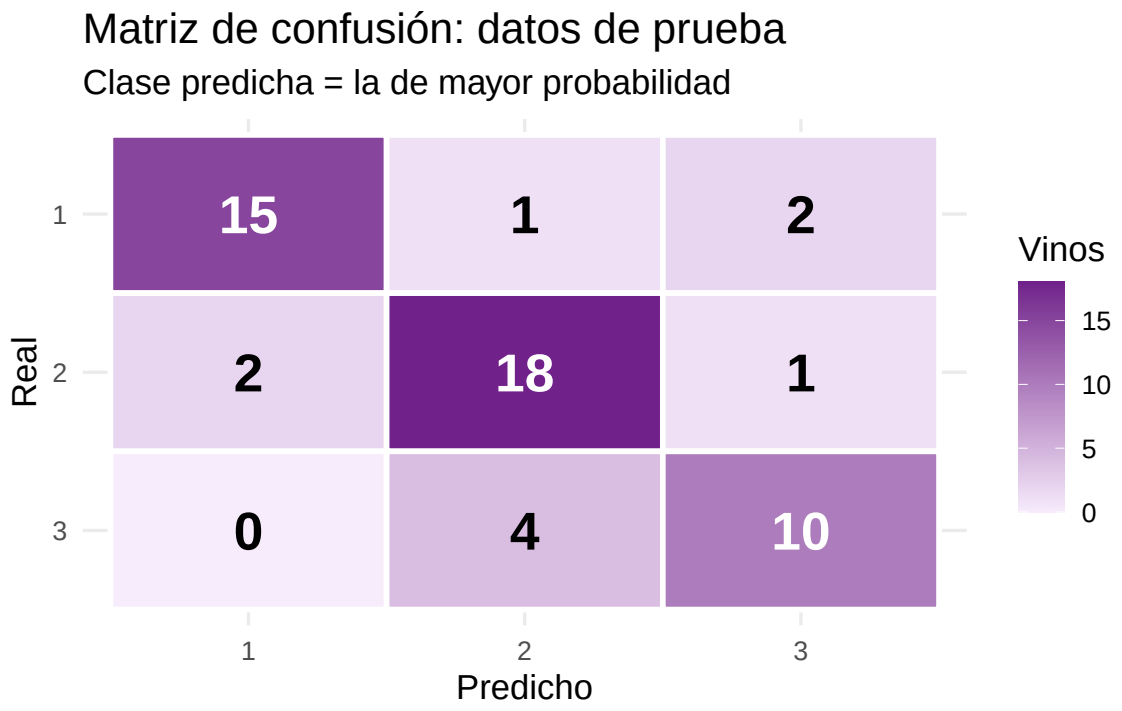


Figura 7: Matriz de confusión en prueba.

```
# Probabilidad media asignada a cada clase, según la clase real
prob_media <- aggregate(as.data.frame(prob_prueba),
                        by = list(Clase_real = prueba$Clase), FUN = mean)
kable(prob_media, digits = 3,
      col.names = c("Clase real", "Prob. clase 1", "Prob. clase 2", "Prob. clase 3"),
      caption = "Probabilidad media estimada por clase real (prueba)")
```

Tabla 9: Probabilidad media estimada por clase real (prueba)

Clase real	Prob. clase 1	Prob. clase 2	Prob. clase 3
1	0.811	0.089	0.100
2	0.098	0.857	0.045
3	0.133	0.175	0.693

```
pm_v <- diag(as.matrix(prob_media[, -1]))
```

La probabilidad media que el modelo asigna a la clase verdadera es 0.811, 0.857, 0.693 para las clases 1, 2 y 3, respectivamente (la diagonal de la tabla anterior).

10.2. Sensibilidad y especificidad por clase

Con tres clases, los indicadores se calculan para cada clase **contra el resto**:

- **Sensibilidad:** proporción de los vinos de la clase que el modelo identifica como de esa clase.
- **Especificidad:** proporción de los vinos de las otras clases que el modelo no asigna a esa clase.
- **Precisión:** proporción de los vinos asignados a la clase que realmente lo son.
- **F1:** media armónica entre precisión y sensibilidad.

```
tabla_clases <- metricas_por_clase(matriz)


# AUC de cada clase contra el resto (probabilidad estimada de esa clase)
roc_lista <- lapply(clases, function(k) {
  roc(response = as.integer(prueba$Clase == k), predictor = prob_prueba[, k],
      levels = c(0, 1), direction = "<", quiet = TRUE)
})
```

```r
names(roc_lista) <- clases
auc_clase <- sapply(roc_lista, function(r) as.numeric(auc(r)))


tabla_eval <- data.frame(tabla_clases, AUC = unname(auc_clase[tabla_clases$Clase]))
promedio <- data.frame(Clase = "Promedio",
                       t(colMeans(tabla_eval[, -1], na.rm = TRUE)))
tabla_eval <- rbind(tabla_eval, promedio)
kable(tabla_eval, digits = 3, row.names = FALSE,
      col.names = c("Clase", "Sensibilidad", "Especificidad", "Precisión",
                    "F1", "AUC"),
      caption = "Indicadores de clasificación por clase en prueba (clase contra el resto)")
```

Tabla 10: Indicadores de clasificación por clase en prueba (clase contra el resto)

Clase	Sensibilidad	Especificidad	Precisión	F1	AUC
1	0.833	0.943	0.882	0.857	0.967
2	0.857	0.844	0.783	0.818	0.966
3	0.714	0.923	0.769	0.741	0.943
Promedio	0.802	0.903	0.811	0.805	0.959

```r
exactitud_bal <- mean(tabla_clases$Sensibilidad)   # exactitud balanceada
tabla_global <- data.frame(
  Indicador = c("Exactitud", "Exactitud de referencia (clase más frecuente)",
                "Exactitud balanceada (promedio de las sensibilidades)",
                "AUC promedio (clase contra el resto)"),
  Valor = c(exactitud_m, exactitud_base, exactitud_bal, mean(auc_clase))
)
kable(tabla_global, digits = 3,
      caption = "Indicadores globales de clasificación en prueba")
```

Tabla 11: Indicadores globales de clasificación en prueba

Indicador	Valor
Exactitud	0.811
Exactitud de referencia (clase más frecuente)	0.396
Exactitud balanceada (promedio de las sensibilidades)	0.802
AUC promedio (clase contra el resto)	0.959

```
txt_sens <- paste(sprintf("clase %s: %.1f %%", tabla_clases$Clase,
                          100 * tabla_clases$Sensibilidad), collapse = "; ")
txt_espe <- paste(sprintf("clase %s: %.1f %%", tabla_clases$Clase,
                          100 * tabla_clases$Especificidad), collapse = "; ")
txt_auc  <- paste(sprintf("clase %s: %.3f", clases, auc_clase), collapse = "; ")
k_peor   <- tabla_clases$Clase[which.min(tabla_clases$Sensibilidad)]
n_clase_prueba <- table(prueba$Clase)
```

Lectura clave: la exactitud mide el porcentaje de clasificaciones correctas; la sensibilidad mide la detección de los vinos de cada clase, y la especificidad, la detección de los vinos que no son de esa clase. En prueba, las sensibilidades fueron: clase 1: 83.3 %; clase 2: 85.7 %; clase 3: 71.4 %. Las especificidades fueron: clase 1: 94.3 %; clase 2: 84.4 %; clase 3: 92.3 %. La clase con menor sensibilidad fue la 3. Los AUC (clase contra el resto) fueron: clase 1: 0.967; clase 2: 0.966; clase 3: 0.943. Como la prueba es pequeña (la clase 3 tiene 14 vinos), cada sensibilidad se apoya en pocos casos y varía bastante de una partición a otra.

```
datos_se <- rbind(
  data.frame(Clase = tabla_clases$Clase, Indicador = "Sensibilidad",
             Valor = tabla_clases$Sensibilidad),
  data.frame(Clase = tabla_clases$Clase, Indicador = "Especificidad",
             Valor = tabla_clases$Especificidad)
)
```

```r
g9 <- ggplot(datos_se, aes(x = Clase, y = Valor, fill = Indicador)) +
  geom_col(position = position_dodge(width = .75), width = .65) +
  geom_text(aes(label = percent(Valor, accuracy = .1)),
            position = position_dodge(width = .75), vjust = -.4, size = 4) +
  scale_fill_manual(values = c(Sensibilidad = "#F47721", Especificidad = "#70218A")) +
  scale_y_continuous(limits = c(0, 1.12), labels = percent) +
  labs(title = "Sensibilidad y especificidad por clase",
       subtitle = "Clase predicha = la de mayor probabilidad",
       x = "Clase de vino (contra el resto)", y = "Porcentaje", fill = NULL) +
  theme_minimal(base_size = 12) + theme(legend.position = "bottom")
print(g9)
```

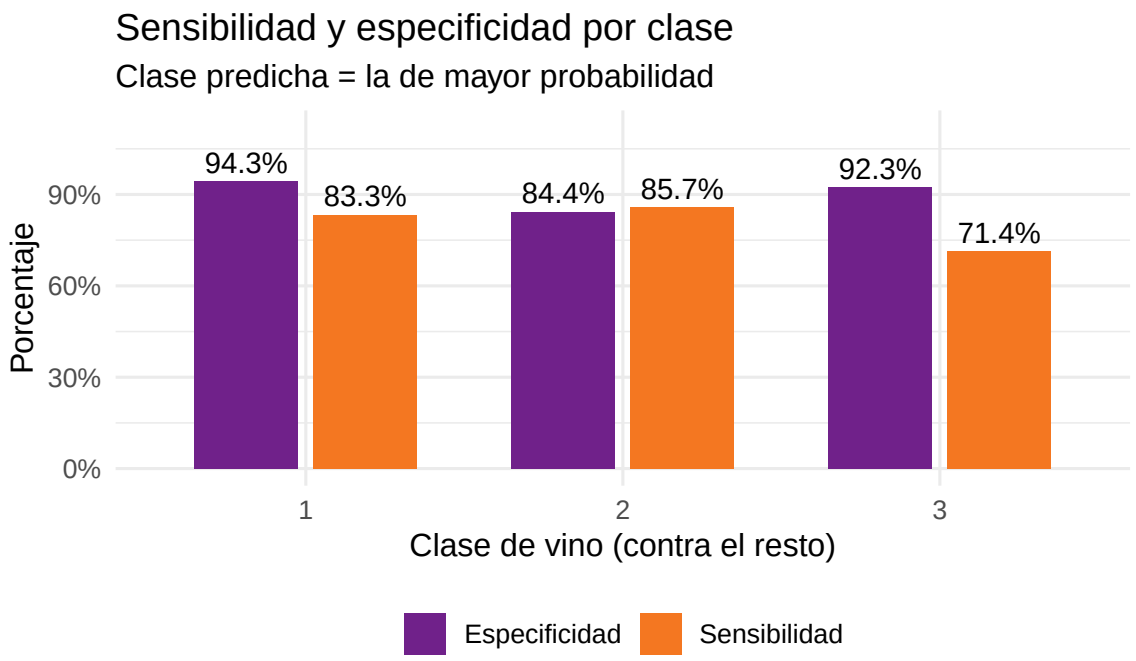


Figura 8: Sensibilidad y especificidad por clase en prueba.

10.3. Curvas ROC en prueba

```r
datos_roc <- do.call(rbind, lapply(clases, function(k) {
  data.frame(Clase = paste0("Clase ", k, " (AUC = ", sprintf("%.3f", auc_clase[k]), ")"),
             Tasa_FP = 1 - roc_lista[[k]]$specificities,
             Sensibilidad = roc_lista[[k]]$sensitivities)
}))
g8 <- ggplot(datos_roc, aes(x = Tasa_FP, y = Sensibilidad, color = Clase)) +
  geom_abline(slope = 1, intercept = 0, linetype = "dashed", color = "grey60") +
  geom_line(linewidth = 1.1) +
  scale_color_manual(values = unname(colores_clase)) +
  coord_equal() +
  labs(title = "Curvas ROC del modelo en datos de prueba",
       subtitle = "Cada clase contra el resto",
       x = "Tasa de falsos positivos (1 - especificidad)",
       y = "Sensibilidad", color = NULL) +
  theme_minimal(base_size = 12) + theme(legend.position = "bottom")
print(g8)
```

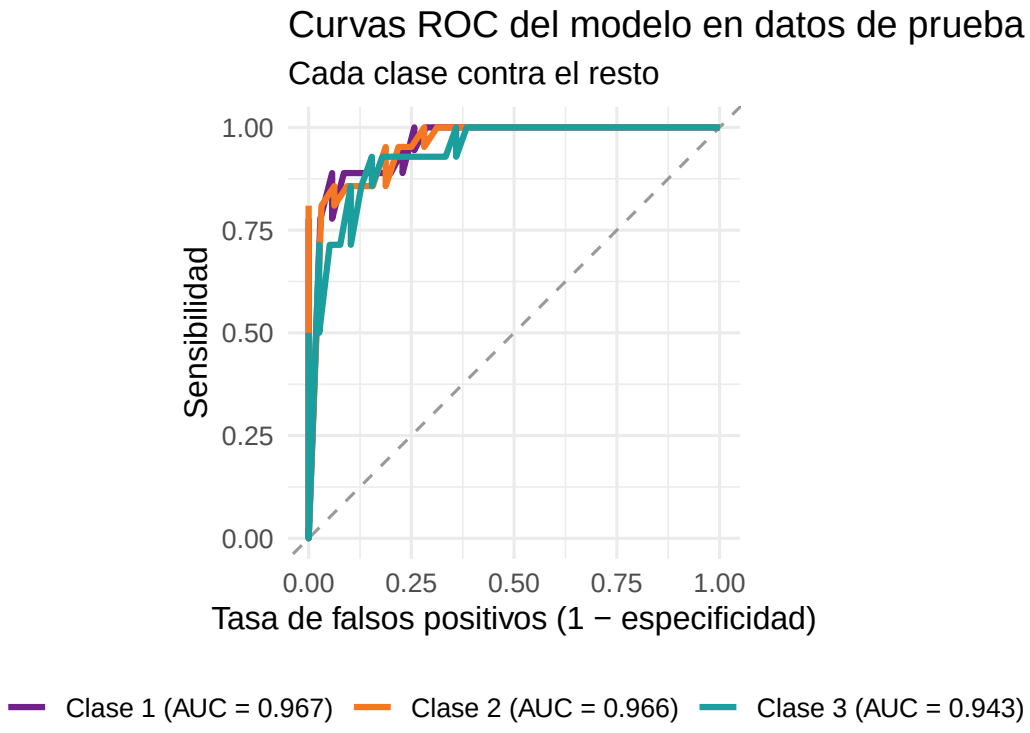


Figura 9: Curvas ROC de cada clase contra el resto en prueba.

10.4. Comparación de umbrales de clasificación

La regla anterior asigna cada vino a la clase de mayor probabilidad. Otra forma de clasificar es fijar un **umbral** para la probabilidad de una clase y decidir que el vino pertenece a ella si la supera. Subir el umbral exige más evidencia: **disminuye la sensibilidad y aumenta la especificidad**; bajarlo hace lo contrario. Se compara cada clase contra el resto con umbrales de 0.20 a 0.80.

```
umbrales <- round(seq(0.20, 0.80, by = 0.10), 2)


tab_umbrales <- do.call(rbind, lapply(clases, function(k) {
  m <- do.call(rbind, lapply(umbrales, function(u) {
    metricas_umbral(prueba$Clase == k, prob_prueba[, k], u)
  }))
  data.frame(Clase = k, m)
```

```
}))


# Una fila por umbral: sensibilidad (Sens.) y especificidad (Esp.) de cada clase
tab_ancha <- data.frame(Umbral = umbrales)
for (k in clases) {
  m <- tab_umbrales[tab_umbrales$Clase == k, ]
  tab_ancha[[paste0("Sens_", k)]] <- m$Sensibilidad
  tab_ancha[[paste0("Esp_", k)]]  <- m$Especificidad
}
kable(tab_ancha, digits = 3, row.names = FALSE,
      col.names = c("Umbral", "Sens. 1", "Esp. 1", "Sens. 2", "Esp. 2",
                    "Sens. 3", "Esp. 3"),
      caption = "Sensibilidad (Sens.) y especificidad (Esp.) en prueba según el umbral; el núme
```

Tabla 12: Sensibilidad (Sens.) y especificidad (Esp.) en prueba según el umbral; el número indica la clase evaluada contra el resto

Umbral	Sens. 1	Esp. 1	Sens. 2	Esp. 2	Sens. 3	Esp. 3
0.2	0.944	0.771	0.952	0.750	0.786	0.897
0.3	0.889	0.829	0.952	0.812	0.714	0.923
0.4	0.889	0.914	0.857	0.812	0.714	0.923
0.5	0.833	0.943	0.857	0.906	0.714	0.923
0.6	0.778	0.943	0.857	0.938	0.714	0.949
0.7	0.778	1.000	0.810	0.938	0.714	0.974
0.8	0.722	1.000	0.810	1.000	0.571	0.974

```
rejilla <- seq(0.02, 0.98, by = 0.02)
curvas_umbral <- do.call(rbind, lapply(clases, function(k) {
  m <- do.call(rbind, lapply(rejilla, function(u) {
    metricas_umbral(prueba$Clase == k, prob_prueba[, k], u)
```

```
  }))
  rbind(
    data.frame(Clase = paste("Clase", k, "contra el resto"), Umbral = m$Umbral,
               Indicador = "Sensibilidad", Valor = m$Sensibilidad),
    data.frame(Clase = paste("Clase", k, "contra el resto"), Umbral = m$Umbral,
               Indicador = "Especificidad", Valor = m$Especificidad)
  )
}))
g10 <- ggplot(curvas_umbral, aes(x = Umbral, y = Valor, color = Indicador)) +
  geom_vline(xintercept = 0.5, linetype = "dashed", color = "grey50") +
  geom_line(linewidth = 1.1) +
  facet_wrap(~ Clase) +
  scale_color_manual(values = c(Sensibilidad = "#F47721", Especificidad = "#70218A")) +
  scale_y_continuous(labels = percent_format(accuracy = 1), limits = c(0, 1)) +
  labs(title = "Sensibilidad y especificidad según el umbral",
       x = "Umbral de probabilidad", y = "Porcentaje", color = NULL) +
  theme_minimal(base_size = 12) + theme(legend.position = "bottom")
print(g10)
```

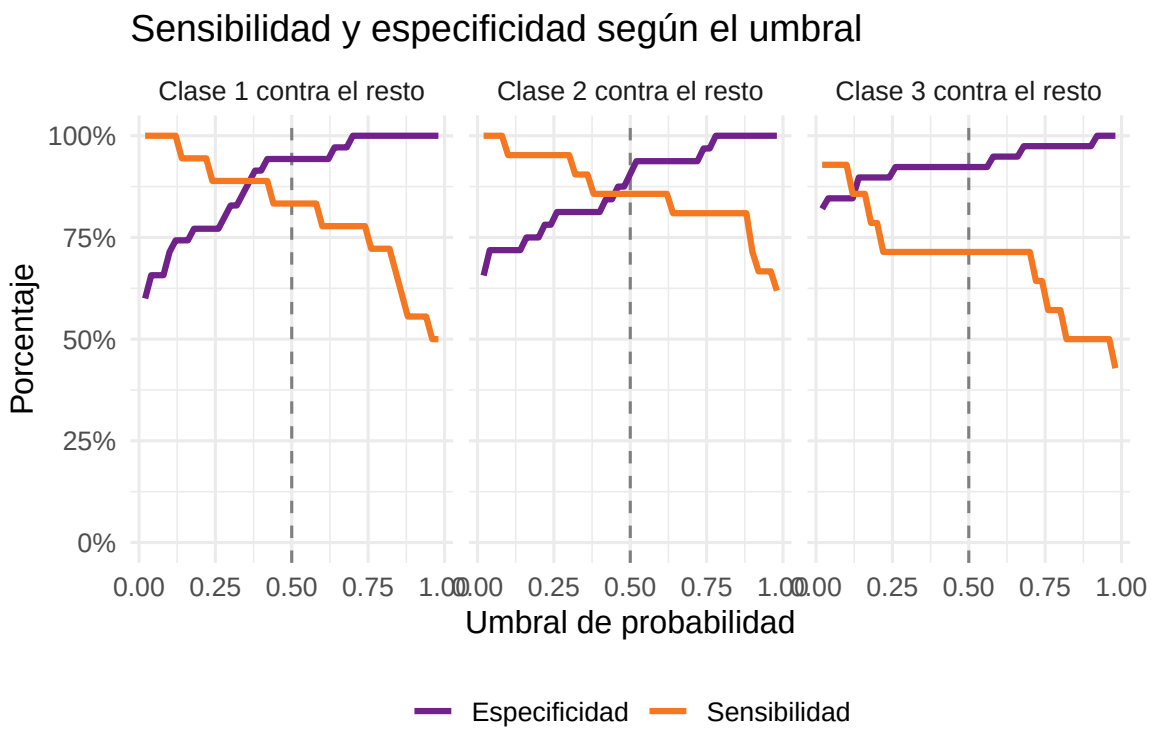


Figura 10: Sensibilidad y especificidad en prueba según el umbral, para cada clase contra el resto (línea punteada: umbral 0.50).

10.4.1. Umbral óptimo elegido en entrenamiento

Un umbral no debe elegirse mirando la muestra de prueba. Por eso, para cada clase se busca en **entrenamiento** el umbral que maximiza el **índice de Youden** (sensibilidad + especificidad − 1) y luego se evalúa **una sola vez** en prueba, comparándolo con el umbral de 0.50.

```
prob_entrenamiento <- predict(modelo_multi, newdata = entrenamiento, type = "probs")
rejilla_opt <- seq(0.05, 0.95, by = 0.01)


umbral_opt <- sapply(clases, function(k) {
  j <- sapply(rejilla_opt, function(u) {
    metricas_umbral(entrenamiento$Clase == k, prob_entrenamiento[, k], u)$Youden
  })
  rejilla_opt[which.max(j)]
```

```
})


tab_comp <- do.call(rbind, lapply(clases, function(k) {
  real <- prueba$Clase == k
  a <- metricas_umbral(real, prob_prueba[, k], 0.50)
  b <- metricas_umbral(real, prob_prueba[, k], umbral_opt[k])
  data.frame(Clase = k, Umbral_opt = unname(umbral_opt[k]),
             Sens_050 = a$Sensibilidad, Esp_050 = a$Especificidad,
             Sens_opt = b$Sensibilidad, Esp_opt = b$Especificidad)
}))
kable(tab_comp, digits = 3, row.names = FALSE,
      col.names = c("Clase", "Umbral óptimo", "Sens. (0.50)", "Esp. (0.50)",
                    "Sens. (óptimo)", "Esp. (óptimo)"),
      caption = "Comparación en prueba entre el umbral 0.50 y el umbral óptimo elegido en entre
```

Tabla 13: Comparación en prueba entre el umbral 0.50 y el umbral óptimo elegido en entrenamiento

Clase	Umbral óptimo	Sens. (0.50)	Esp. (0.50)	Sens. (óptimo)	Esp. (óptimo)
1	0.18	0.833	0.943	0.944	0.771
2	0.80	0.857	0.906	0.810	1.000
3	0.32	0.714	0.923	0.714	0.923

- *Clase 1 contra el resto:* con umbral 0.50, sensibilidad 83.3 % y especificidad 94.3 %; con el umbral 0.18 (óptimo en entrenamiento), sensibilidad 94.4 % y especificidad 77.1 %.
- *Clase 2 contra el resto:* con umbral 0.50, sensibilidad 85.7 % y especificidad 90.6 %; con el umbral 0.80 (óptimo en entrenamiento), sensibilidad 81.0 % y especificidad 100.0 %.
- *Clase 3 contra el resto:* con umbral 0.50, sensibilidad 71.4 % y especificidad 92.3 %; con el umbral 0.32 (óptimo en entrenamiento), sensibilidad 71.4 % y especificidad 92.3 %.

Lectura clave: el umbral cambia el equilibrio entre detectar los vinos de una clase (sensibilidad) y evitar asignar vinos de otras clases (especificidad). Elegir el umbral depende de qué

error resulta más costoso para la empresa. Dos precauciones: (1) el umbral de 0.50 aplicado a cada clase por separado no coincide exactamente con la regla de la mayor probabilidad, pues un vino puede tener su mayor probabilidad por debajo de 0.50; (2) los umbrales por clase son un análisis de *clase contra el resto* y no forman por sí solos una regla única de decisión entre las tres clases.

11. Estabilidad del modelo

Los resultados anteriores dependen de una sola partición con 53 vinos de prueba. Para evaluar qué tan estable es el modelo, se repitió **200 veces** la partición estratificada 70 % / 30 %, ajustando el modelo multinomial en cada una y guardando la exactitud, la sensibilidad y la especificidad de cada clase, y los coeficientes.

```
set.seed(123)
B <- 200
acc_rep   <- numeric(B)
convergio <- logical(B)
sens_rep  <- matrix(NA_real_, nrow = B, ncol = length(clases),
                    dimnames = list(NULL, clases))
esp_rep   <- sens_rep
coef_rep  <- NULL

for (b in seq_len(B)) {
  p_b <- particion_estratificada(Datos_modelo, prop = 0.70)
  m_b <- multinom(Clase ~ Alcohol + Acido_Malico + Intensidad_Color,
                  data = p_b$entrenamiento, trace = FALSE, maxit = 500)
  pred_b <- predict(m_b, newdata = p_b$prueba, type = "class")
  real_b <- p_b$prueba$Clase

  convergio[b] <- (m_b$convergence == 0)
```

```
  acc_rep[b]   <- mean(pred_b == real_b)
  for (k in clases) {
    sens_rep[b, k] <- mean(pred_b[real_b == k] == k)    # sensibilidad
    esp_rep[b, k]  <- mean(pred_b[real_b != k] != k)    # especificidad
  }
  coef_rep <- rbind(coef_rep, as.vector(coef(m_b)))
}
co_b <- coef(m_b)
colnames(coef_rep) <- as.vector(outer(rownames(co_b), colnames(co_b),
                                      paste, sep = ": "))
cat("Ajustes que convergieron:", sum(convergio), "de", B, "\n")
```

```
## Ajustes que convergieron: 200 de 200
```

```
# Resumen de la exactitud (en porcentaje)
res_acc <- data.frame(
  Media = mean(acc_rep), DE = sd(acc_rep), Minimo = min(acc_rep),
  P2.5 = quantile(acc_rep, 0.025), Mediana = median(acc_rep),
  P97.5 = quantile(acc_rep, 0.975), Maximo = max(acc_rep),
  row.names = NULL
)
kable(round(100 * res_acc, 1),
      caption = "Exactitud en prueba (porcentaje) en 200 particiones aleatorias")
```

Tabla 14: Exactitud en prueba (porcentaje) en 200 particiones aleatorias

Media	DE	Minimo	P2.5	Mediana	P97.5	Maximo
86.5	3.6	75.5	79.2	86.8	92.5	98.1

```r
ggplot(data.frame(acc = 100 * acc_rep), aes(x = acc)) +
  geom_histogram(bins = 15, fill = "#70218A", color = "white") +
  geom_vline(xintercept = 100 * mean(acc_rep), linetype = "dashed") +
  labs(title = "Exactitud en 200 particiones",
       x = "Exactitud en prueba (%)", y = "Número de particiones") +
  theme_minimal(base_size = 12)
```

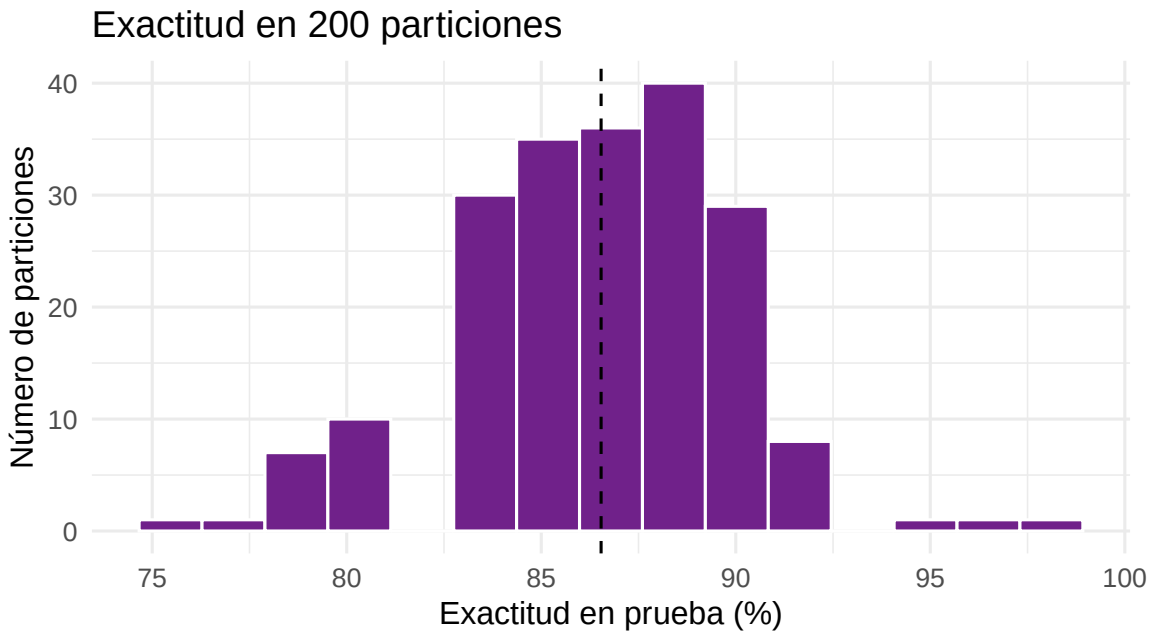


Figura 11: Distribución de la exactitud en datos de prueba al repetir la partición 200 veces (línea: media).

```r
# Sensibilidad y especificidad de cada clase en las 200 particiones (porcentaje)
res_se <- data.frame(
  Clase = clases,
  Sens_media = 100 * colMeans(sens_rep),
  Sens_P2.5  = 100 * apply(sens_rep, 2, quantile, 0.025),
  Sens_P97.5 = 100 * apply(sens_rep, 2, quantile, 0.975),
  Esp_media  = 100 * colMeans(esp_rep),
  Esp_P2.5   = 100 * apply(esp_rep, 2, quantile, 0.025),
  Esp_P97.5  = 100 * apply(esp_rep, 2, quantile, 0.975)
```

```
)
kable(res_se, digits = 1, row.names = FALSE,
      col.names = c("Clase", "Sens. media", "Sens. P2.5", "Sens. P97.5",
                    "Esp. media", "Esp. P2.5", "Esp. P97.5"),
      caption = "Sensibilidad y especificidad por clase en 200 particiones (porcentaje; P = per
```

Tabla 15: Sensibilidad y especificidad por clase en 200 particiones (porcentaje; P = percentil)

Clase	Sens. media	Sens. P2.5	Sens. P97.5	Esp. media	Esp. P2.5	Esp. P97.5
1	86.4	72.1	100	91.6	82.9	100
2	86.9	76.2	100	93.9	84.3	100
3	86.1	64.3	100	94.2	87.2	100

```
# Estabilidad de los coeficientes (sin interceptos)
cr <- coef_rep[, !grepl("Intercept", colnames(coef_rep))]
tab_est <- data.frame(
  Coeficiente = colnames(cr),
  Media       = colMeans(cr),
  DE          = apply(cr, 2, sd),
  OR_mediana  = exp(apply(cr, 2, median)),
  OR_p2.5     = exp(apply(cr, 2, quantile, 0.025)),
  OR_p97.5    = exp(apply(cr, 2, quantile, 0.975)),
  Mismo_signo = 100 * apply(cr, 2, function(x) mean(sign(x) == sign(mean(x)))),
  row.names = NULL
)
kable(tab_est, digits = 3,
      col.names = c("Coeficiente", "Media", "DE", "OR mediana", "OR P2.5",
                    "OR P97.5", "Porcentaje con el mismo signo"),
      caption = "Estabilidad de los coeficientes en 200 particiones")
```

Tabla 16: Estabilidad de los coeficientes en 200 particiones

Coeficiente	Media	DE	OR mediana	OR P2.5	OR P97.5	Porcentaje con el mismo signo
2: Alcohol	-4.940	0.925	0.009	0.001	0.028	100.0
3: Alcohol	-3.773	0.611	0.026	0.005	0.062	100.0
2: Acido_Malico	-0.198	0.461	0.860	0.227	1.782	66.5
3: Acido_Malico	1.795	0.283	5.878	3.892	11.556	100.0
2: Intensidad_Color	-1.688	0.651	0.208	0.052	0.397	100.0
3: Intensidad_Color	1.176	0.202	3.163	2.398	5.164	100.0

```
incluyen1 <- tab_est$Coeficiente[tab_est$OR_p2.5 < 1 & tab_est$OR_p97.5 > 1]
texto_inc <- if (length(incluyen1) > 0) paste(incluyen1, collapse = ", ") else "ninguno"
menos_est <- tab_est$Coeficiente[which.min(tab_est$Mismo_signo)]

# Criterios para el veredicto: DE de la exactitud <= 3 puntos y
# signo igual en al menos 95% de las repeticiones
acc_estable   <- sd(acc_rep) <= 0.03
signo_estable <- min(tab_est$Mismo_signo) >= 95
```

Interpretación: al repetir la partición, la exactitud en prueba tuvo una media de 86.5 % y una desviación estándar de 3.6 puntos; el 95 % central de los valores está entre 79.2 % y 92.5 %, con extremos de 75.5 % y 98.1 %. La exactitud de 81.1 % obtenida con la partición inicial es, por lo tanto, una de las muchas posibles, y lo razonable es reportar el rango. La sensibilidad media por clase fue de 86.4 %, 86.9 %, 86.1 % y la especificidad media de 91.6 %,

93.9 %, 94.2 % para las clases 1, 2 y 3, respectivamente. En cuanto a los coeficientes, el signo se mantuvo en al menos el 66.5 % de las repeticiones en todos los casos; el coeficiente menos estable fue 2: Acido_Malico. Los intervalos de los odds ratios que incluyen el valor 1 (sin efecto) corresponden a: 2: Acido_Malico.

En resumen: la exactitud varía bastante entre particiones (desviación estándar de 3.6 puntos; se considera estable si es de 3 puntos o menos) y la dirección de algunos efectos no es estable (2: Acido_Malico cambia de signo en parte de las repeticiones) (el signo se mantiene en al menos 95 % de las repeticiones en cada coeficiente). Por lo tanto, el modelo no puede considerarse completamente estable y sus resultados deben interpretarse con cautela, dado el tamaño reducido de la muestra (178 vinos). Los intervalos de este análisis describen la variación por partición con los mismos 178 vinos, por lo que no equivalen a la incertidumbre de muestrear vinos nuevos.

12. Conclusiones y proyección

```
etiquetas_var <- c(Alcohol = "el alcohol", Acido_Malico = "el ácido málico",
                   Intensidad_Color = "la intensidad del color")
# Fuerza de la asociación: promedio de |log(OR por DE)| en las dos comparaciones
fuerza <- tapply(abs(log(tab_multi$OR_por_DE)), tab_multi$Variable, mean)
orden  <- names(sort(fuerza, decreasing = TRUE))
sig_var <- tapply(tab_multi$Valor_p < 0.05, tab_multi$Variable, any)
txt_sig <- if (any(sig_var)) {
  paste(etiquetas_var[names(sig_var)[sig_var]], collapse = ", ")
} else "ninguna variable"
```

El modelo multinomial permite relacionar el alcohol, el ácido málico y la intensidad del color con los odds de que un vino pertenezca a la clase 2 o a la clase 3 en lugar de la clase 1. Con una desviación estándar como unidad, el orden de mayor a menor asociación fue: la intensidad del color, el alcohol, el ácido málico. Tienen al menos una comparación significativa al

5 %: el ácido málico, el alcohol, la intensidad del color.

La evaluación con datos separados muestra resultados más informativos que evaluar el mismo conjunto utilizado en el ajuste: en prueba, la exactitud fue de 81.1 % (frente a 39.6 % de predecir siempre la clase más frecuente), con sensibilidades de clase 1: 83.3 %; clase 2: 85.7 %; clase 3: 71.4 % y especificidades de clase 1: 94.3 %; clase 2: 84.4 %; clase 3: 92.3 %. La sensibilidad más baja correspondió a la clase 3. Al repetir 200 veces la partición, la exactitud promedio fue de 86.5 % (desviación estándar de 3.6 puntos), por lo que conviene reportar la exactitud como un rango y no como un valor único. La comparación de umbrales mostró que moverlos intercambia sensibilidad por especificidad en cada clase.

Limitaciones: el análisis principal usa una sola partición entrenamiento/prueba (la sección de estabilidad la repite 200 veces con los mismos 178 vinos); la muestra es pequeña y la prueba tiene 53 vinos, de modo que la sensibilidad de cada clase se apoya en pocos casos; solo se usaron tres predictores, elegidos por su interpretabilidad y por la exploración descriptiva, sin compararlos con otros posibles; los umbrales por clase son un análisis de clase contra el resto y no una regla única entre las tres clases; el umbral óptimo se eligió en entrenamiento con el índice de Youden, que da el mismo peso a ambos errores, y en una aplicación real debería ponderarse según su costo; las observaciones del conjunto no permiten inferir causalidad ni garantizar resultados en otra empresa. En un trabajo posterior puede evaluarse la selección del umbral mediante validación cruzada **dentro del entrenamiento**, reservando la prueba para la evaluación final.

Aporte del proyecto de aula: aprender a preparar datos, ajustar e interpretar un modelo estadístico, evaluar su desempeño y comunicar resultados mediante un informe reproducible.

13. Comparación final de los modelos

Aspecto	Logístico binario	Logístico multinomial
Número de categorías de respuesta	2 (abandona / no abandona)	3 (clases de vino 1, 2 y 3)
Categoría de referencia	No abandona (0); se modela la probabilidad del evento 1	Clase 1; las clases 2 y 3 se comparan contra ella
Interpretación de coeficientes	Un solo conjunto de coeficientes; exp(coef) es el OR del abandono frente a la permanencia	Un conjunto de coeficientes por cada clase frente a la referencia; exp(coef) es el OR de esa clase frente a la clase 1
Tipo de probabilidades estimadas	Una probabilidad, P(abandono), con P(no abandono) = 1 - P	Un vector de tres probabilidades que suma 1; se clasifica en la de mayor valor
Sensibilidad y especificidad	Un solo par de valores (evento = abandono)	Un par por clase, calculado como clase contra el resto
Umbral de clasificación	Un umbral sobre P(abandono) (0.50 en el Caso 1)	Regla de la mayor probabilidad, o un umbral por clase (clase contra el resto)
Curva ROC y AUC	Una curva y un AUC	Una curva y un AUC por clase (clase contra el resto)

Reflexión final: el modelo binario se usa cuando la respuesta tiene dos categorías, como abandona o no abandona; el multinomial, cuando hay tres o más categorías nominales sin orden, como los tipos de vino. En ambos casos, interpretar las probabilidades y los odds ratios describe la **asociación** entre predictores y respuesta en los datos con que se ajustó el modelo, mientras que comprobar el desempeño con datos nuevos mide si el modelo **generaliza**. Un modelo puede ajustar bien la muestra de entrenamiento y fallar con observaciones nuevas, por eso se reservaron datos de prueba para la matriz de confusión, la sensibilidad y la especificidad.

En el caso binario la exactitud sola puede ser engañosa si una clase es minoritaria, y en el multinomial conviene mirar la sensibilidad de cada clase y no solo la exactitud global. Finalmente, el umbral de clasificación es una decisión que debe tomarse con datos de entrenamiento y según el costo de cada tipo de error, no mirando la muestra de prueba.